

École Supérieure Privée de Management de Tunis

Esprit School of Business



RAPPORT DE STAGE

En vue de l'obtention du diplôme de Licence en Business Computing

Parcours Business Intelligence

Soutenu le : _____

Réalisé par : **Malek Ben Drissia**

« Plateforme de Pilotage et de Prédiction des Ventes
des Contrats à Facture chez Orange Tunisie »

Février 2026 – Juin 2026

Maître de stage : M. Oussema Benyahia

Encadrant académique : M. Aymen Ben Brik

Année universitaire 2025/2026

	<i>Nom & Prénom</i>	<i>Date et Signature</i>
Maître de stage		
Encadrant académique		

Dédicace

Je dédie ce modeste travail,

À la mémoire de mon cher frère Anas Ben Drissia,

Allah yarhamek wa yaskanouk fasih jannatih.

Tu n'es plus parmi nous physiquement, mais ton âme illumine encore chaque instant de ma vie. Ton absence est un vide que rien ne saurait combler, mais ta présence demeure gravée à jamais dans chacun de mes pas. Tout au long de ce parcours, ton souvenir m'a accompagné comme une lumière qui guide même les nuits les plus sombres.

À chaque obstacle franchi, à chaque réussite obtenue, j'ai pensé à toi, certain que tu serais fier de moi de là où tu te trouves désormais. Ce travail t'est dédié, mon frère, parce que ton amour et ton inspiration ne se sont jamais éteints. Tu vis à travers chaque page de ce rapport, chaque ligne de code, chaque effort que j'ai fourni.

Tu resteras pour toujours mon grand frère, mon modèle, et ma fierté la plus profonde. Que Dieu t'accueille dans Son vaste paradis aux côtés de Ses prophètes et de Ses bien-aimés.

À mon cher père, Monsieur Tarek Ben Drissia,

Mon premier modèle, mon repère et mon protecteur. Tu m'as transmis le sens du travail, de la rigueur et de la persévérance. Tes sacrifices silencieux et ton amour inconditionnel ont éclairé chacune des étapes de ma vie. Aucun mot ne saurait exprimer toute ma reconnaissance pour ce que tu as fait, et ce que tu continues de faire pour moi. Que Dieu te garde et t'accorde une longue vie auprès de nous.

À ma très chère mère, Madame Hanen Boubaker,

Le soleil qui réchauffe notre foyer, la source intarissable d'amour et de tendresse. Tes prières silencieuses, tes encouragements et ta présence bienveillante ont été mes plus grandes forces. Tu es l'âme de cette famille, et tout ce que je suis aujourd'hui, je te le dois. Que Dieu te préserve et te récompense pour tous tes sacrifices.

À ma chère sœur Nermin,

Pour ta tendresse, ta complicité et ton soutien constant durant toutes les étapes de mes études. Tu as toujours été là, dans les joies comme dans les épreuves.

À mon cher frère Nassim,

Pour ta complicité fraternelle, pour les rires partagés et le soutien sincère que tu m'as toujours apporté.

Remerciements

Au terme de ce projet de fin d'études, je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réussite de ce travail.

Je tiens d'abord à remercier chaleureusement mon **encadrant académique**, Monsieur **Ay-men Ben Brik**, pour son accompagnement rigoureux, ses conseils avisés et ses critiques constructives tout au long de ce projet. Sa disponibilité, sa pédagogie et son expertise ont été des atouts précieux dans la réalisation de ce travail.

Je tiens également à exprimer ma sincère reconnaissance à mon **maître de stage** au sein de la Direction Commerciale d'Orange Tunisie, Monsieur **Oussema Benyahia**, pour la confiance qu'il m'a accordée, pour son encadrement professionnel, ainsi que pour les échanges enrichissants qui ont nourri ma compréhension du métier et orienté efficacement les choix techniques du projet.

Mes remerciements vont également à l'ensemble de l'équipe de la **Direction Commerciale d'Orange Tunisie** pour leur accueil bienveillant, leur disponibilité et la qualité des informations qu'ils ont bien voulu partager avec moi durant toute la période du stage.

Je remercie également tous les **enseignants de l'Esprit School of Business**, qui m'ont accompagné durant mon parcours académique et m'ont transmis les connaissances et les compétences nécessaires à l'aboutissement de ce projet.

J'adresse aussi mes remerciements aux **membres du jury** qui m'ont fait l'honneur d'évaluer ce travail. Leurs remarques et suggestions contribueront sans nul doute à l'enrichissement de mes réflexions futures.

Enfin, je tiens à exprimer ma plus profonde gratitude à ma **famille** et à mes **proches** pour

leur soutien moral constant, leur patience et leurs encouragements tout au long de mon parcours universitaire.

À toutes et à tous, merci.

Table des matières

Liste des Sigles et Acronymes	x
Introduction Générale	1
1 Cadre Général du Projet	3
Introduction	3
1.1 Présentation de l'Organisme d'Accueil	3
1.1.1 Orange Tunisie	3
1.1.2 Secteurs d'activité	4
1.1.3 Missions	4
1.1.4 Organigramme d'Orange Tunisie	5
1.2 Présentation du Projet	6
1.2.1 Analyse de l'existant	6
1.2.2 Critique de l'existant	7
1.2.3 Problématique	8
1.2.4 Solution proposée	8
1.3 Méthodologie de Travail	9
1.3.1 Comparaison entre approche traditionnelle et approche agile	9
1.3.2 Étude comparative entre les méthodes Agile	10
1.3.3 Choix de Scrum pour la gestion du projet	11
1.3.4 Discussion sur l'approche CRISP-DM	12
Conclusion	13
2 Spécification des Besoins et Mise en Place avec Scrum	14
Introduction	14
2.1 Analyse des Besoins	14
2.1.1 Identification des acteurs	14

2.1.2	Besoins fonctionnels	16
2.1.3	Besoins non fonctionnels	18
2.1.4	Identification des KPIs	19
2.2	Mise en Place du Projet avec Scrum	20
2.2.1	Distribution des rôles	20
2.2.2	Backlog Produit	21
2.2.3	Sprint Backlog	23
2.2.4	Diagramme de Gantt	24
	Conclusion	24
3	Conception Multidimensionnelle	25
	Introduction	25
3.1	Sprint Backlog du Sprint 2	25
3.2	Analyse Exploratoire des Données	27
3.2.1	Présentation des données sources	27
3.2.2	Analyse univariée	28
3.2.3	Analyse bivariée	30
3.3	Conception Multidimensionnelle	30
3.3.1	Choix de l'approche	30
3.3.2	Choix du schéma conceptuel	31
3.3.3	Tables de dimensions	32
3.3.4	Tables de faits	34
3.3.5	Schéma final	36
	Conclusion	37
4	Processus ETL	38
	Introduction	38
4.1	Sprint Backlog du Sprint 3	38
4.2	Présentation du Processus ETL	39
4.3	Environnement Technologique	40
4.3.1	Comparaison des outils ETL	40
4.3.2	Comparaison des SGBD	41

4.4	Réalisation de l'ETL	42
4.4.1	Module d'Extraction	42
4.4.2	Module de Transformation	42
4.4.3	Module de Chargement	43
4.4.4	Module de Data Quality	44
4.5	Visualisation sur pgAdmin	45
	Conclusion	46
5	Application Web et Reporting	47
	Introduction	47
5.1	Sprint Backlog du Sprint 4	47
5.2	Modélisation Machine Learning	48
5.2.1	Approche méthodologique	48
5.2.2	Clustering des vendeurs	51
5.2.3	Détection d'anomalies	54
5.2.4	Régression et prédiction des ventes	57
5.2.5	Forecasting de clôture mensuelle	59
5.2.6	Classification des paiements	61
5.3	Architecture de l'application Flask	65
5.3.1	Choix du framework	65
5.3.2	Patron architectural : MVC + Blueprints	65
5.3.3	Structure du projet	67
5.3.4	Stack technique	67
5.4	Authentification et gestion des utilisateurs	67
5.4.1	Trois rôles applicatifs	68
5.4.2	Mécanisme de sécurité	68
5.5	Tableaux de bord interactifs	69
5.5.1	Tableau de bord <i>Performance</i>	70
5.5.2	Tableau de bord <i>Objectifs</i>	71
5.5.3	Tableau de bord <i>Prediction</i>	72
5.5.4	Tableau de bord <i>Paiements</i>	74
5.6	Chatbot analytique ORYA	74

5.6.1	Présentation et objectifs	74
5.6.2	Architecture technique	75
5.6.3	Extrait du code de l'agent	76
5.7	Maquette comparative Power BI	76
5.7.1	Objectif de la maquette	76
5.7.2	Connexion et modèle sémantique	76
5.7.3	Tableaux de bord développés sous Power BI	77
5.7.4	Tableau comparatif	77
	Conclusion	77
6	Extensions, tests et validation	79
	Introduction	79
6.1	Interface dédiée Data Engineer	79
6.1.1	Objectif de l'interface	79
6.1.2	Fonctionnalités proposées	80
6.1.3	Apport pour le profil technique	85
6.2	Tests unitaires et validation technique	86
6.2.1	Objectifs des tests	86
6.2.2	Périmètre de validation	86
6.2.3	Synthèse des résultats techniques	86
6.3	Évaluation des modèles de Machine Learning	87
6.3.1	Rappel des modèles développés	87
6.3.2	Critères d'évaluation	87
6.3.3	Interprétation des résultats	88
6.4	Validation business	88
6.4.1	Conformité aux besoins exprimés	88
6.4.2	Apports pour Orange Tunisie	89
6.4.3	Limites identifiées	89
	Conclusion	89
	Conclusion Générale et Perspectives	90
	Webographie	91

Table des figures

1.1	Logo officiel d'Orange Tunisie	4
1.2	Les quatre piliers du plan stratégique Engage 2025	5
1.3	Organigramme simplifié des directions d'Orange Tunisie	6
1.4	Processus actuel de suivi des ventes chez Orange Tunisie	7
1.5	Le cycle Scrum et ses événements	12
2.1	Diagramme de cas d'utilisation global	16
2.2	Diagramme de Gantt du projet de plateforme décisionnelle Orange Tunisie	24
3.1	Synthèse visuelle des livrables du Sprint 2	27
3.2	Distribution des ventes par canal de vente	29
3.3	Histogramme des durées d'engagement des contrats	29
3.4	Croisement canal $\times$ mois — taux de réalisation des objectifs	30
3.5	Création de la table dim_vendeur sous PostgreSQL	34
3.6	Création de la table fact_ventes sous PostgreSQL	35
3.7	Création de la table fact_objectifs	36
3.8	Schéma en constellation du Data Warehouse orange_dwh	37
4.1	Architecture du processus ETL en Python	40
4.2	Extrait du module d'extraction	42
4.3	Module de transformation ETL	43
4.4	Extrait du module de chargement	44
4.5	Pipeline du module Data Quality au sein de l'ETL	45
4.6	Vue d'ensemble du Data Warehouse orange_dwh sous pgAdmin 4	46
5.1	Workflow général de modélisation Machine Learning	50
5.2	Chargement et préparation des données depuis le DWH	51
5.3	Choix du nombre optimal de clusters : méthode du coude et silhouette	53
5.4	Entraînement du modèle K-Means	53

5.5	Répartition des vendeurs selon les clusters identifiés	54
5.6	Comparaison des algorithmes de détection d'anomalies	55
5.7	Résultats de la détection d'anomalies par GAN	56
5.8	Détection d'anomalies par Isolation Forest	56
5.9	Consensus des anomalies détectées par les algorithmes	57
5.10	Comparaison des performances des algorithmes de régression	59
5.11	Entraînement du modèle Prophet	60
5.12	Évolution de la fonction de perte lors de l'entraînement du modèle LSTM	61
5.13	Comparaison des performances des algorithmes de classification	63
5.14	Classement final des algorithmes de classification	63
5.15	Courbes ROC des modèles de classification du paiement	64
5.16	Architecture MVC + Blueprints de l'application Flask	66
5.17	Arborescence du projet Flask	67
5.18	Implémentation de la route de connexion (Blueprint auth)	68
5.19	Page de connexion de la plateforme	69
5.20	Tableau de bord Performance Commerciale	70
5.21	Synthèse et recommandations automatiques générées par l'IA	71
5.22	Synthèse automatique des objectifs commerciaux	72
5.23	Synthèse automatique des prévisions de ventes	73
5.24	Endpoint d'inférence Prophet	73
5.25	Synthèse automatique du suivi des paiements	74
5.26	Architecture du chatbot analytique ORYA	75
5.27	Agent d'interprétation ORYA (extrait)	76
6.1	Page d'accueil de l'interface Data Quality	81
6.2	Vue d'ensemble — erreurs par table et types d'erreurs	82
6.3	Détail par table — exploration table par table	82
6.4	Alertes de qualité — 5 critiques et 8 attention	83
6.5	Explorateur d'erreurs — navigation dans les 13 fichiers	83
6.6	Historique des exécutions — 342 logs	84
6.7	Notifications email — rapports automatiques	84
6.8	Lancement du pipeline ETL et des tests pytest	85
6.9	Extrait de l'interface de supervision Data Quality	85

Liste des tableaux

1.1	Limites du système existant	8
1.2	Comparaison entre l'approche traditionnelle et l'approche agile	10
1.3	Tableau comparatif entre Scrum, Kanban et XP	11
2.1	Synthèse des KPIs retenus pour le projet	20
2.2	Identification des rôles Scrum	21
2.3	Backlog Produit du projet	22
2.4	Sprint Backlog du projet	23
3.1	Sprint Backlog du Sprint 2 — Réalisation du DWH et de l'ETL	26
3.2	Présentation des sources de données du projet	28
3.3	Comparaison entre les approches Inmon et Kimball	31
3.4	Comparaison des schémas dimensionnels	32
3.5	Détail des tables de dimensions	33
4.1	Sprint Backlog du Sprint 3 — Processus ETL	39
4.2	Comparaison des outils ETL évalués	41
4.3	Comparaison des SGBD candidats	41
5.1	Sprint Backlog du Sprint 4 – Application Web et Reporting	48
5.2	Comparaison des algorithmes de <i>clustering</i>	52
5.3	Personas vendeurs issus du <i>clustering</i> K-Means	54
5.4	Comparaison des algorithmes de détection d'anomalies	55
5.5	Comparaison des algorithmes de régression	58
5.6	Comparaison des algorithmes de <i>forecasting</i>	60
5.7	Comparaison des algorithmes de classification des paiements	62
5.8	Comparaison des <i>frameworks</i> web Python	65
5.9	Permissions par rôle applicatif	68
5.10	Comparaison entre l'application Flask développée et Power BI	77

6.1	Synthèse des anomalies détectées par le module Data Quality	80
6.2	Indicateurs globaux de qualité des données	81
6.3	Synthèse des tests techniques réalisés	87
6.4	Critères d'évaluation des modèles Machine Learning	88

Liste des Sigles et Acronymes

AI / IA	Artificial Intelligence	LSTM	Long Short-Term Memory
ANN	Artificial Neural Network	MAE	Mean Absolute Error
API	Application Programming Interface	MAPE	Mean Absolute Percentage Error
AUC	Area Under Curve	ML	Machine Learning
B2B	Business to Business	MLP	Multi-Layer Perceptron
BI	Business Intelligence	MVC	Modèle-Vue-Contrôleur
CRISP-DM	Cross-Industry Standard Process	NLP	Natural Language Processing
CSV	Comma-Separated Values	ORYA	Orange Reporting Your Assistant
DAX	Data Analysis Expressions	PCA	Principal Component Analysis
DBSCAN	Density-Based Spatial Clustering	PFE	Projet de Fin d'Études
DWH	Data Warehouse	REST	Representational State Transfer
EDA	Exploratory Data Analysis	RMSE	Root Mean Square Error
ETL	Extract, Transform, Load	ROC	Receiver Operating Characteristic
GAN	Generative Adversarial Network	SGBD	Système de Gestion de BdD
HTML	HyperText Markup Language	SQL	Structured Query Language
HTTP	HyperText Transfer Protocol	SVM	Support Vector Machine
JSON	JavaScript Object Notation	UML	Unified Modeling Language
KNN	K-Nearest Neighbors	WSGI	Web Server Gateway Interface
KPI	Key Performance Indicator	XGBoost	Extreme Gradient Boosting
LLM	Large Language Model		

Introduction Générale

À l'ère du numérique, la donnée s'est imposée comme une ressource stratégique au même titre que les ressources financières ou humaines. Sa maîtrise conditionne désormais la capacité des entreprises à piloter leur activité, à anticiper les évolutions du marché et à prendre des décisions éclairées dans des délais toujours plus courts. Dans un secteur aussi concurrentiel et dynamique que celui des télécommunications, cette exigence se traduit par un besoin croissant d'outils décisionnels performants, capables d'agréger, d'analyser et de valoriser des volumes importants de données commerciales.

La **Business Intelligence** (BI) s'inscrit pleinement dans cette dynamique. En combinant entrepôts de données, processus d'intégration et tableaux de bord interactifs, elle permet de transformer des données brutes et dispersées en indicateurs stratégiques directement exploitables par les décideurs. Couplée aux récents progrès de l'**apprentissage automatique** et de l'**intelligence artificielle**, elle ouvre aujourd'hui la voie à une nouvelle génération de solutions décisionnelles, capables non seulement de décrire ce qui s'est passé, mais aussi de prédire ce qui pourrait se produire et de recommander des actions adaptées.

C'est dans ce contexte que s'inscrit le présent projet de fin d'études, réalisé au sein d'**Orange Tunisie**, filiale du Groupe Orange et l'un des principaux opérateurs de télécommunications en Tunisie. Le projet a été mené au sein de la Direction Commerciale, dont l'activité repose en grande partie sur le suivi quotidien des ventes des contrats à facture et sur le pilotage de l'atteinte des objectifs commerciaux mensuels.

Or, ce suivi s'appuie actuellement sur des fichiers Excel dispersés et des rapports statiques produits manuellement. Cette organisation génère plusieurs limites majeures : absence de vision consolidée et en temps réel des performances, difficulté à comparer les résultats par offre, par canal ou par vendeur, absence de mécanisme prédictif pour anticiper la clôture des ventes en fin de mois, et suivi insuffisant des paiements de factures. Autant de freins qui pèsent sur la réactivité et la qualité de la prise de décision commerciale.

Pour répondre à cette problématique, nous avons conçu et mis en place une **plateforme décisionnelle complète**, intégrant un entrepôt de données, une application web de pilotage, des modèles de Machine Learning et un assistant conversationnel intelligent. Une maquette comparative a également été réalisée sous Power BI, afin de positionner la solution développée

par rapport aux outils de reporting standards du marché.

Les chapitres présentés dans ce rapport sont répartis comme suit :

- **Premier chapitre** : Présentation de l'environnement professionnel dans lequel le projet a été réalisé, étude critique de l'existant, formulation de la problématique métier, et choix méthodologique (Scrum).
- **Deuxième chapitre** : Spécification des besoins fonctionnels et non fonctionnels, identification des acteurs et des indicateurs clés (KPIs), puis mise en place du cadre Scrum (rôles, Backlog Produit, Sprint Backlog, diagramme de Gantt).
- **Troisième chapitre** : Conception multidimensionnelle du Data Warehouse orange_dwh sous PostgreSQL, précédée d'une analyse exploratoire des données sources et justification du schéma en constellation retenu.
- **Quatrième chapitre** : Mise en œuvre du processus ETL en Python, incluant l'extraction des huit sources opérationnelles, la transformation et le nettoyage des données, le chargement dans le DWH, et la validation sous pgAdmin.
- **Cinquième chapitre** : Réalisation de l'application web Flask intégrant les cinq modèles de Machine Learning (clustering, détection d'anomalies, régression, forecasting Prophet, classification), les quatre tableaux de bord interactifs, le chatbot analytique ORYA et la maquette comparative Power BI.
- **Sixième chapitre** : Extensions et validations : interface dédiée au Data Engineer pour la supervision de la qualité des données, tests unitaires, évaluation des modèles de Machine Learning et validation business des résultats obtenus.

Enfin, la **Conclusion générale** portera sur une synthèse globale du travail réalisé, mettra en évidence les apports du projet pour Orange Tunisie et présentera les perspectives d'évolution envisagées. En combinant les approches de la Business Intelligence, du Machine Learning et de l'intelligence artificielle conversationnelle, nous visons à doter Orange Tunisie d'un environnement de travail plus agile, plus prédictif et résolument tourné vers la décision augmentée par les données.

Chapitre 1

Cadre Général du Projet

Plan

- 1.1 Présentation de l'Organisme d'Accueil
- 1.2 Présentation du Projet
- 1.3 Méthodologie de Travail
- 1.4 Conclusion

Introduction

Ce premier chapitre a pour objectif de présenter le **cadre général** dans lequel s'inscrit le présent projet de fin d'études, réalisé au sein d'**Orange Tunisie**. Nous introduirons dans un premier temps l'organisme d'accueil, en exposant ses activités, sa position sur le marché et son organisation interne. Nous enchaînerons ensuite avec la présentation du projet, à travers une étude et une critique de l'existant, afin de mettre clairement au jour la problématique et de justifier la solution proposée. Nous finirons par la définition de la **méthodologie de gestion** retenue pour la conduite du projet, à savoir Scrum, ainsi qu'une brève discussion sur le choix d'une démarche unifiée plutôt qu'une approche hybride spécifique à la Data Science.

1.1 Présentation de l'Organisme d'Accueil

Dans cette section, nous présentons l'organisme d'accueil **Orange Tunisie**.

1.1.1 Orange Tunisie

Orange Tunisie est une entreprise tunisienne de télécommunications qui offre des services de téléphonie mobile, d'Internet et de services à valeur ajoutée à ses clients. Elle a été lancée commercialement le **5 mai 2010**, après avoir obtenu une licence de télécommunications de la part du gouvernement tunisien.

Orange Tunisie est une filiale du **Groupe Orange**, un groupe de télécommunications français présent dans de nombreux pays à travers le monde. L'entreprise est l'un des principaux opérateurs de télécommunications en Tunisie, avec environ **4,5 millions de clients** et près de **1 100 collaborateurs**. Son réseau couvre les **24 gouvernorats** du pays en 4G, à travers un réseau de distribution composé de **24 boutiques** et de **49 franchises**. Orange Tunisie est reconnue pour son engagement envers la technologie et l'innovation, ainsi que pour sa volonté de fournir des services de haute qualité.



Figure 1.1 – Logo officiel d'Orange Tunisie

1.1.2 Secteurs d'activité

Orange Tunisie propose une gamme complète de services, notamment :

- ✓ La **téléphonie mobile** (prépayé, postpayé, forfaits) ;
- ✓ L'**accès à Internet** (ADSL, fibre optique, 3G, 4G) ;
- ✓ La **téléphonie fixe** et les services aux particuliers ;
- ✓ Les **services aux entreprises** (B2B, intégration, sécurité) ;
- ✓ Les **services financiers mobiles** (Orange Money).

1.1.3 Missions

Les missions d'Orange Tunisie consistent à fournir des services de télécommunications de qualité supérieure, à développer son réseau et à promouvoir l'innovation, tout en contribuant au développement économique et social de la Tunisie. L'essence de sa stratégie d'opérateur innovant, responsable et solidaire repose sur deux piliers principaux :

- ✓ **Fixe, mobile et Internet haut débit** : Orange Tunisie conçoit, développe et exploite des réseaux fixes et mobiles afin d'offrir à ses clients une connectivité enrichie par les possibilités du haut débit (ADSL, fibre optique, 3G, 4G).
- ✓ **Services aux entreprises** : elle fournit des services d'infrastructure, d'intégration et des solutions numériques aux entreprises de toutes tailles, pour accompagner leur transformation numérique.

La stratégie globale s'inscrit dans le plan **Engage 2025** du Groupe Orange, qui place **la data et l'intelligence artificielle au cœur du modèle d'innovation**. C'est précisément dans cette dynamique que s'inscrit notre projet.



Figure 1.2 – Les quatre piliers du plan stratégique Engage 2025

1.1.4 Organigramme d'Orange Tunisie

La figure 1.3 présente une vue simplifiée de l'organisation d'Orange Tunisie. Le projet a été réalisé au sein de la Direction Commerciale, plus précisément dans le département Business Intelligence et Pilotage Commercial, chargé de l'analyse des performances commerciales et de l'aide à la décision.




Figure 1.3 – Organigramme simplifié des directions d'Orange Tunisie

Le stage s'est déroulé sous la supervision de **M. Oussema Benyahia**, maître de stage, avec pour mission principale la conception et la mise en place d'une solution décisionnelle dédiée au suivi et à la prédiction des ventes des contrats à facture.

1.2 Présentation du Projet

Cette section présente le cadre opérationnel du projet à travers une analyse approfondie du système existant chez Orange Tunisie, l'identification de ses limites, la formulation de la problématique métier et la solution décisionnelle proposée.

1.2.1 Analyse de l'existant

Actuellement, le suivi des ventes des contrats à facture chez Orange Tunisie repose principalement sur des extractions de données issues de différentes sources opérationnelles. Ces données sont ensuite consolidées dans des fichiers Excel afin de produire des rapports manuels destinés au pilotage commercial.

Cette approche permet d'obtenir une vision globale de l'activité commerciale, mais elle présente plusieurs limites en termes de rapidité, de fiabilité et d'aide à la décision.




Figure 1.4 – Processus actuel de suivi des ventes chez Orange Tunisie

Comme l'illustre la figure 1.4, le suivi des ventes des contrats à facture repose sur des extractions manuelles des données opérationnelles. Ces données sont ensuite consolidées dans des fichiers Excel afin de produire des rapports statiques destinés au pilotage commercial. Cette approche présente plusieurs limites, notamment un manque d'automatisation, une faible réactivité dans la prise de décision ainsi que l'absence de mécanismes avancés de prévision et d'analyse.

1.2.2 Critique de l'existant

Après l'analyse du système actuel, plusieurs insuffisances ont été identifiées.

Limite	Impact
Données dispersées dans plusieurs sources	Difficulté d'accès à une information centralisée
Traitements manuels sous Excel	Risque d'erreurs humaines et perte de temps
Absence de tableaux de bord interactifs	Faible visibilité sur les indicateurs de performance
Absence de prévisions commerciales	Difficulté d'anticipation des résultats futurs
Absence de contrôle de qualité des données	Risque d'incohérences dans les analyses

Table 1.1 – Limites du système existant

Ces limites montrent la nécessité de moderniser le processus de pilotage commercial afin de réduire les traitements manuels, d'améliorer la fiabilité des données et de renforcer la capacité d'anticipation des responsables commerciaux.

1.2.3 Problématique

Face à ces limites, un besoin concret émerge. La problématique centrale de ce projet peut être formulée de la manière suivante :

« Comment concevoir et mettre en place une plateforme décisionnelle intégrée permettant de centraliser, de visualiser, de prédire et de fiabiliser les performances de ventes des contrats à facture chez Orange Tunisie, afin d'améliorer le suivi des objectifs commerciaux, le contrôle des paiements et la qualité de la prise de décision ? »

1.2.4 Solution proposée

Pour répondre à ces enjeux, le projet consiste à concevoir et déployer une **plateforme décisionnelle complète**, combinant les apports de la **Business Intelligence** et de l'**intelligence**

artificielle. Cette solution a pour objectif de transformer les données commerciales brutes en informations stratégiques claires, accessibles et exploitables.

La solution s'articule autour de **quatre axes fonctionnels** principaux :

- **La centralisation des données** : mise en place d'un entrepôt de données unique, structuré et fiable, regroupant l'ensemble des informations commerciales actuellement dispersées ;
- **La visualisation interactive** : conception d'une application web offrant des tableaux de bord dynamiques pour le suivi des ventes, des objectifs et des paiements ;
- **L'analyse prédictive** : intégration de modèles de Machine Learning pour anticiper la clôture des ventes, détecter les anomalies, segmenter les vendeurs et identifier les risques d'impayés ;
- **L'accès en langage naturel** : intégration d'un assistant conversationnel intelligent permettant aux utilisateurs d'interroger leurs données sans compétences techniques.

Les détails techniques des outils et technologies retenus pour la mise en œuvre de cette solution seront présentés dans les chapitres suivants.

1.3 Méthodologie de Travail

Un projet informatique, quelle que soit sa taille et la portée de ses objectifs, nécessite la mise en place d'une démarche structurée tout au long de son cycle de vie. Une méthodologie peut être définie comme une démarche fournissant un cadre et des notations standards qui aident à concevoir des solutions de qualité. Notre projet combine plusieurs natures de livrables : un entrepôt de données, une application web, des tableaux de bord interactifs ainsi que plusieurs modèles de Machine Learning. Le choix de la méthodologie doit donc tenir compte de cette diversité.

1.3.1 Comparaison entre approche traditionnelle et approche agile

Il est important de bien choisir la méthode de travail qui répond aux besoins du projet. Le tableau 1.2 ci-dessous compare l'approche traditionnelle et l'approche agile sur plusieurs critères.

Aspect	Approche Traditionnelle	Approche Agile
Cycle de vie	Séquentiel, phases distinctes	Itératif et incrémental
Planification	Détaillée et fixe	Flexible et évolutive
Documentation	Abondante et exhaustive	Limitée au nécessaire
Équipe	Rôles spécialisés, chef de projet	Auto-organisée, collaborative
Qualité	Contrôle à la fin du cycle	Contrôle continu et intégré
Changement	Minimisés, gérés avec prudence	Acceptés et intégrés rapidement
Gestion des risques	Processus formalisé	Continue et intégrée

Table 1.2 – Comparaison entre l'approche traditionnelle et l'approche agile

Suite à cette analyse, nous avons opté pour l'**approche Agile**, qui correspond davantage à la nature évolutive de notre projet et aux besoins de validation continue avec le maître de stage.

1.3.2 Étude comparative entre les méthodes Agile

Le tableau 1.3 ci-dessous présente une comparaison entre les trois méthodes agiles les plus répandues : Scrum, Kanban et Extreme Programming (XP).

Caractéristique	Scrum	Kanban	XP
Cycle de vie	Itératif (sprints)	Flux continu	Itérations courtes
Rôles définis	Oui (PO, SM, Dev)	Non	Oui
Planification	Par sprint (2-4 semaines)	Continue	Par itération
Livraison	À chaque sprint	En continu	Fréquente
Flexibilité	Élevée	Très élevée	Élevée
Pratiques techniques	Non imposées	Non imposées	Très poussées
Adapté aux projets BI	Oui — recommandé	Partiellement	Non

Table 1.3 – Tableau comparatif entre Scrum, Kanban et XP

1.3.3 Choix de Scrum pour la gestion du projet

Après examen des différentes méthodes agiles, nous avons retenu **Scrum** comme méthodologie de gestion pour l'ensemble de notre projet, en raison de plusieurs facteurs déterminants :

- sa nature **itérative et incrémentale**, parfaitement adaptée à un projet livrant progressivement plusieurs composants (DWH, ETL, modèles ML, application web, dashboards) ;
- la **souplesse des sprints**, qui permet d'ajuster les priorités au fur et à mesure des retours du maître de stage ;
- la **clarté des rôles**, qui facilite la communication entre l'équipe et les parties prenantes ;
- sa capacité à **couvrir l'intégralité du périmètre** de notre projet, qu'il s'agisse de la partie BI (entrepôt de données, ETL, dashboards) ou de la partie Data Science (modèles de Machine Learning).

Scrum repose sur trois rôles fondamentaux :

- Le **Product Owner** : responsable de la définition et de la priorisation des besoins ;
- Le **Scrum Master** : garant du bon déroulement du processus ;
- L'**équipe de développement** : responsable de la réalisation technique.

Et sur quatre événements réguliers :

- Le **Sprint Planning** : planification du sprint ;
- Le **Daily Scrum** : réunion quotidienne de synchronisation ;
- La **Sprint Review** : présentation des résultats ;
- La **Sprint Retrospective** : analyse et amélioration.



Figure 1.5 – Le cycle Scrum et ses événements

1.3.4 Discussion sur l'approche CRISP-DM

La méthodologie **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*) est souvent évoquée comme référence pour la conduite de projets analytiques. Elle s'organise autour de six phases itératives : compréhension métier, compréhension des données, préparation des données, modélisation, évaluation et déploiement.

Cependant, après analyse, nous avons choisi de **ne pas retenir CRISP-DM** pour notre projet, et ce pour plusieurs raisons :

- **CRISP-DM est conçu pour un objectif analytique unique**, alors que notre projet comporte **plusieurs objectifs distincts** de Machine Learning : segmentation des vendeurs (clustering), détection d'anomalies, prédiction des ventes (régression), prévision de clôture mensuelle (forecasting) et classification des paiements ;
- CRISP-DM ne prévoit qu'**une seule phase d'évaluation finale**, ce qui n'est pas adapté à un projet où chaque modèle nécessite sa propre stratégie d'évaluation avec des métriques différentes ;
- Une part importante de notre projet (mise en place du Data Warehouse, processus ETL, conception des tableaux de bord, application web) **ne relève pas du Data Mining** au sens strict et n'entre donc pas dans le périmètre de CRISP-DM.

Pour ces raisons, nous avons opté pour une **approche unifiée fondée sur Scrum**, capable de structurer l'ensemble des livrables du projet, qu'il s'agisse de la partie BI ou de la partie Data Science. Chaque modèle de Machine Learning sera développé au sein d'un sprint dédié, avec ses propres critères d'évaluation, comme nous le verrons dans les chapitres suivants.

Conclusion

Au terme de ce premier chapitre, nous avons introduit l'entreprise d'accueil, **Orange Tunisie**, et mis notre projet dans son contexte. Nous avons présenté ses activités, son organisation interne et le département au sein duquel le stage s'est déroulé.

Nous avons ensuite exposé les termes généraux du projet à travers une **étude de l'existant**, une **critique des limites actuelles**, la formulation de la **problématique** et la proposition d'une **solution décisionnelle complète**, articulée autour de la centralisation des données, de la visualisation interactive, de l'analyse prédictive et de l'accès aux données en langage naturel.

Enfin, nous avons clôturé ce chapitre par le choix de la méthodologie **Scrum** retenue pour la conduite de notre projet. Cette approche, fondée sur des sprints itératifs et incrémentaux, nous permettra de structurer efficacement l'ensemble des livrables, qu'ils concernent la partie Business Intelligence (entrepôt de données, ETL, dashboards) ou la partie Data Science (modèles de Machine Learning). Nous avons également justifié le choix de ne pas adopter la méthodologie CRISP-DM, jugée inadaptée à la pluralité des objectifs analytiques de notre projet.

Le chapitre suivant sera consacré à l'**analyse détaillée des besoins** et à la **conception** de la solution proposée.

Chapitre 2

Spécification des Besoins et Mise en Place avec Scrum

Plan

- 2.1 Analyse des Besoins
- 2.2 Mise en Place du Projet avec Scrum
- 2.3 Conclusion

Introduction

Ce deuxième chapitre est consacré à la **spécification des besoins** du projet et à la **mise en place du cadre de travail** selon la méthodologie Scrum retenue dans le chapitre précédent.

Dans un premier temps, nous identifions les **acteurs** impliqués dans le système et nous détaillons les **besoins fonctionnels** et **non fonctionnels** qui guideront la réalisation de la solution. Nous présentons également les **indicateurs clés de performance (KPIs)** retenus pour mesurer la performance commerciale d'Orange Tunisie.

Dans un second temps, nous exposons l'organisation du travail à travers la **définition des rôles Scrum**, l'élaboration du **Backlog Produit**, la planification des **Sprint Backlogs** et la présentation du **diagramme de Gantt** du projet.

2.1 Analyse des Besoins

2.1.1 Identification des acteurs

Dans le cadre du développement de la plateforme décisionnelle de suivi des ventes des contrats à facture chez Orange Tunisie, plusieurs acteurs interagissent avec le système. Ces acteurs ont été identifiés en fonction de leur rôle et de leur niveau d'implication dans l'utilisation

de la solution.

Administrateur

L'**administrateur** est responsable de la gestion technique et fonctionnelle de la plateforme. Il assure la maintenance du Data Warehouse, le bon fonctionnement des processus ETL, la mise à jour des données et la gestion des droits d'accès. Il dispose d'un accès complet à toutes les fonctionnalités de l'application, y compris la gestion des utilisateurs.

Responsable commercial

Le **responsable commercial** est le principal utilisateur métier de la solution. Il consulte les tableaux de bord pour suivre les performances de ventes journalières, analyser l'atteinte des objectifs mensuels et contrôler les paiements de factures. Il utilise également les prévisions de ventes et les analyses prédictives pour orienter ses décisions commerciales.

Data Engineer

Le **Data Engineer** est responsable de la qualité des données et du bon fonctionnement du pipeline ETL. Il dispose d'un accès spécifique au module de Data Quality, lui permettant de superviser les anomalies détectées, les doublons et les incohérences dans les données sources.

Diagramme de cas d'utilisation global

La figure 2.1 ci-dessous présente le diagramme de cas d'utilisation global du système, illustrant les interactions entre les différents acteurs et les fonctionnalités principales de la plateforme.




Figure 2.1 – Diagramme de cas d'utilisation global

2.1.2 Besoins fonctionnels

Dans le cadre de la mise en place de la solution décisionnelle, plusieurs besoins fonctionnels ont été identifiés afin de garantir une couverture optimale des exigences métier d'Orange Tunisie.

Authentification et gestion des utilisateurs

La solution doit permettre une **authentification sécurisée** des utilisateurs et une gestion fine des droits d'accès selon les rôles définis (administrateur, responsable commercial, data engineer). L'administrateur doit pouvoir ajouter, bloquer ou supprimer des utilisateurs.

Centralisation des données

La solution doit permettre de centraliser l'ensemble des données commerciales issues des différentes sources dans un entrepôt de données unique, structuré et fiable.

Suivi des ventes journalières

La solution doit permettre de visualiser et d'analyser les ventes journalières des contrats à facture selon plusieurs axes : type d'offre, ligne de produit, canal de vente, entité commerciale et vendeur.

Suivi de l'atteinte des objectifs

La solution doit offrir un suivi en temps réel de l'atteinte des objectifs commerciaux mensuels, avec une comparaison entre objectifs fixés et réalisations effectives.

Prédiction de clôture des ventes

La solution doit intégrer un **modèle prédictif** permettant d'estimer la clôture des ventes en fin de mois, à partir des données historiques et des tendances actuelles.

Suivi des paiements de factures

La solution doit intégrer un module dédié au suivi des paiements de factures mensuelles des clients, permettant d'identifier les impayés, les retards et les clients à risque.

Détection d'anomalies

La solution doit permettre la détection automatique des **anomalies** dans les ventes ou les paiements, à l'aide d'algorithmes de Machine Learning.

Visualisation interactive

La solution doit proposer des **tableaux de bord interactifs**, offrant une lecture claire et synthétique des indicateurs clés de performance, avec des filtres adaptés à chaque profil d'utilisateur.

Chatbot analytique

La solution doit intégrer un **assistant conversationnel intelligent** permettant aux utilisateurs d'interroger leurs données en langage naturel et d'obtenir des analyses sans nécessiter de compétences techniques.

Module de qualité des données

La solution doit comporter un module dédié à la **Data Quality**, permettant de surveiller, signaler et corriger les anomalies présentes dans les données sources.

2.1.3 Besoins non fonctionnels

En complément des besoins fonctionnels, plusieurs exigences non fonctionnelles ont été définies pour garantir la qualité, la performance et la pérennité de la solution.

Performance et temps de réponse

La solution doit assurer un **chargement rapide** des tableaux de bord et des rapports, même lorsque les volumes de données sont importants. Un temps de réponse optimal est indispensable pour garantir une expérience utilisateur fluide.

Sécurité et contrôle d'accès

L'accès aux données et aux rapports doit être strictement limité aux utilisateurs autorisés. La gestion des droits d'accès doit être mise en place de manière claire et efficace, avec une **authentification sécurisée**.

Évolutivité

La solution doit être conçue de manière à pouvoir s'adapter à une **croissance progressive** du volume des données et du nombre d'utilisateurs, sans que cela n'affecte les performances.

Facilité d'utilisation

Les interfaces proposées doivent être **intuitives et simples à utiliser**, permettant à tous les profils d'utilisateurs, y compris ceux ayant peu d'expérience technique, d'accéder facilement aux informations essentielles.

Maintenabilité

La solution doit être conçue avec une **architecture claire et modulaire** (MVC, Blueprints), accompagnée d'une documentation suffisante, afin de faciliter les mises à jour et les évolutions futures.

Fiabilité et qualité des données

La solution doit garantir la **fiabilité** et la **cohérence** des données présentées, à travers un module de Data Quality permettant de détecter et de corriger les anomalies.

Respect de la charte graphique

L'interface utilisateur doit respecter strictement la **charte graphique d'Orange Tunisie** : couleur emblématique orange (#FF6600), typographie Helvetica Neue, et règle d'équilibre des couleurs (60% couleurs principales dont 15% d'orange minimum, 40% maximum de couleurs secondaires).

2.1.4 Identification des KPIs

Pour mesurer la performance commerciale d'Orange Tunisie, plusieurs **indicateurs clés de performance (KPIs)** ont été identifiés en concertation avec le maître de stage. Ces indicateurs constituent le cœur du système décisionnel et orientent à la fois la conception des tableaux de bord et le développement des modèles prédictifs.

KPIs de performance commerciale

- **Total des ventes** : nombre total de contrats à facture vendus sur une période donnée ;
- **Taux de réalisation des objectifs** : rapport entre les ventes réalisées et les objectifs fixés (%) ;
- **Évolution des ventes** : progression mensuelle et annuelle des ventes ;
- **Top vendeurs** : classement des vendeurs selon le nombre de ventes réalisées ;
- **Top boutiques et franchises** : classement des entités commerciales selon leurs performances ;
- **Répartition par offre et ligne de produit** : analyse de la performance par catégorie de produit.

KPIs de paiement

- **Taux de paiement de la première facture** : pourcentage de clients ayant payé leur première facture ;
- **Durée d'engagement moyenne** : durée moyenne pendant laquelle un client reste engagé ;
- **Détection des clients à risque** : identification des clients susceptibles de ne pas payer.

KPIs de qualité des données

- **Nombre d'erreurs détectées** : nombre total d'incohérences relevées dans les données ;
- **Taux de complétude** : pourcentage de champs renseignés dans les données sources ;
- **Taux de doublons** : pourcentage d'enregistrements dupliqués détectés.

Le tableau 2.1 ci-dessous synthétise les principaux KPIs retenus pour le projet.

KPI	Catégorie	Unité
Total des ventes	Commercial	Nombre de contrats
Taux de réalisation	Commercial	Pourcentage (%)
Top vendeurs	Commercial	Classement
Top boutiques/franchises	Commercial	Classement
Taux de paiement 1 ^{ère} facture	Paieement	Pourcentage (%)
Durée d'engagement	Paieement	Mois
Clients à risque	Paieement	Liste
Erreurs détectées	Qualité données	Nombre
Taux de complétude	Qualité données	Pourcentage (%)

Table 2.1 – Synthèse des KPIs retenus pour le projet

2.2 Mise en Place du Projet avec Scrum

Cette section présente l'organisation du projet selon la méthodologie Scrum retenue. Nous détaillons la **distribution des rôles**, l'élaboration du **Backlog Produit**, la planification des **Sprint Backlogs** et la présentation du **diagramme de Gantt** du projet.

2.2.1 Distribution des rôles

La mise en œuvre de la méthodologie Scrum nécessite la définition claire des rôles au sein de l'équipe projet. Le tableau 2.2 ci-dessous présente la répartition des rôles adoptée dans le cadre de ce projet.

Rôle Scrum	Responsable	Responsabilités
Product Owner	M. Oussema Benyahia (Maître de stage)	Définir les besoins, prioriser le backlog, valider les livrables
Scrum Master	M. Aymen Ben Brik (Encadrant académique)	Faciliter le processus Scrum, lever les obstacles, assurer le suivi
Équipe de développement	Malek Ben Drissia (Stagiaire)	Concevoir, développer et tester la solution complète

Table 2.2 – Identification des rôles Scrum

2.2.2 Backlog Produit

Le **Backlog Produit** est un outil central de la gestion agile représentant une liste structurée et évolutive des éléments à développer pour répondre aux besoins du projet. Il regroupe, de manière priorisée, les **user stories**, les fonctionnalités à réaliser et les tâches associées.

Le Backlog Produit élaboré dans le cadre de ce projet est organisé en cinq sprints couvrant la durée totale du stage. Le tableau 2.3 ci-dessous présente l'ensemble des user stories identifiées.

Sprint	Thème	User Story	Priorité
Sprint 1	Analyse & Conception	En tant qu'équipe, nous souhaitons analyser les besoins et concevoir l'architecture globale	1
Sprint 1	Analyse & Conception	En tant qu'équipe, nous souhaitons comprendre la structure des données sources	1
Sprint 1	Analyse & Conception	En tant qu'équipe, nous souhaitons concevoir le modèle multidimensionnel du DWH	1
Sprint 2	DWH & ETL	En tant qu'équipe, nous souhaitons implémenter le Data Warehouse sous PostgreSQL	2
Sprint 2	DWH & ETL	En tant qu'équipe, nous souhaitons développer le pipeline ETL en Python	2
Sprint 2	DWH & ETL	En tant qu'équipe, nous souhaitons implémenter le module de Data Quality	2
Sprint 3	Machine Learning	En tant qu'équipe, nous souhaitons développer les modèles de clustering et d'anomalies	3
Sprint 3	Machine Learning	En tant qu'équipe, nous souhaitons développer les modèles de prédiction et de forecasting	3
Sprint 3	Machine Learning	En tant qu'équipe, nous souhaitons développer le modèle de classification des paiements	3
Sprint 4	Application Web	En tant qu'utilisateur, je souhaite m'authentifier et accéder aux dashboards	4
Sprint 4	Application Web	En tant qu'utilisateur, je souhaite consulter les tableaux de bord interactifs	4
Sprint 4	Application Web	En tant qu'utilisateur, je souhaite interroger les données via le chatbot ORYA	4
Sprint 5	Tests & Livraison	En tant qu'équipe, nous souhaitons valider la solution par des tests complets	5

2.2.3 Sprint Backlog

La planification détaillée de chaque sprint est présentée dans le tableau 2.4 ci-dessous. Elle précise pour chaque sprint la **période de réalisation**, les **objectifs visés** et les **tâches principales** à accomplir.

Sprint	Période	Objectif	Tâches principales
Sprint 1	Mois 1	Analyse et Conception	Analyse des besoins, identification des acteurs, conception du modèle multidimensionnel, choix de l'architecture technique
Sprint 2	Mois 2	DWH PostgreSQL et ETL	Création de la base orange_dwh, implémentation des dimensions et tables de faits, développement du pipeline ETL Python, module Data Quality
Sprint 3	Mois 3	Machine Learning	Développement des 6 notebooks ML : EDA, Clustering, Anomalies, Régression, Forecasting (Prophet), Classification
Sprint 4	Mois 4	Application Flask	Développement de l'application Flask, intégration des dashboards Chart.js, intégration du chatbot ORYA (Gemini API)
Sprint 5	Mois 5	Tests et Livraison	Tests unitaires (pytest), évaluation des modèles ML, maquette comparative Power BI, documentation finale

Table 2.4 – Sprint Backlog du projet

2.2.4 Diagramme de Gantt

Le **diagramme de Gantt** permet de visualiser la planification temporelle du projet, en représentant la durée de chaque sprint et l'enchaînement des principales tâches. La figure 2.2 ci-dessous présente le diagramme de Gantt établi pour la conduite de notre projet.




Figure 2.2 – Diagramme de Gantt du projet de plateforme décisionnelle Orange Tunisie

Le projet s'étale sur une durée totale de **cinq mois**, répartis en cinq sprints d'environ un mois chacun. Chaque sprint donne lieu à une livraison fonctionnelle validée par le maître de stage lors d'une **Sprint Review**, conformément aux principes de la méthodologie Scrum.

Conclusion

Au terme de ce deuxième chapitre, nous avons formalisé l'ensemble des besoins du projet et organisé le cadre de travail selon la méthodologie Scrum retenue dans le chapitre précédent.

L'**identification des acteurs**, la **définition des besoins fonctionnels et non fonctionnels**, ainsi que l'identification des **indicateurs clés de performance** ont permis de poser un cadre fonctionnel clair pour la suite du projet. L'élaboration du **Backlog Produit**, du **Sprint Backlog** et du **diagramme de Gantt** constitue quant à elle le fondement opérationnel qui guidera la réalisation de la solution tout au long des chapitres suivants.

Le chapitre suivant sera consacré à la **réalisation du Data Warehouse** et à la **mise en œuvre du processus ETL**, correspondant aux deux premiers sprints du projet.

Chapitre 3

Conception Multidimensionnelle

Plan

- 3.1 Sprint Backlog du Sprint 2
- 3.2 Analyse Exploratoire des Données
- 3.3 Conception Multidimensionnelle
- 3.4 Conclusion

Introduction

Ce troisième chapitre est consacré à la conception du Data Warehouse qui constituera le socle de la plateforme décisionnelle. Avant d'aborder la modélisation dimensionnelle proprement dite, nous présentons l'analyse exploratoire des données sources afin de comprendre leur structure, leur volumétrie et leurs caractéristiques. Cette compréhension oriente directement les choix architecturaux réalisés dans la suite du chapitre.

3.1 Sprint Backlog du Sprint 2

Conformément à la méthodologie Scrum adoptée, le Sprint 2 a été planifié au cours d'une réunion de *Sprint Planning* tenue à l'issue du Sprint 1. L'objectif principal du sprint a été défini comme suit : « *Mettre en place un Data Warehouse fiable et opérationnel, alimenté par un processus ETL automatisé, et intégrant un module de contrôle de la qualité des données* ».

Le tableau 3.1 ci-dessous présente la décomposition du Sprint 2 en tâches techniques, leur priorité ainsi que l'estimation de leur charge.

ID	Tâche	Catégorie	Priorité	Charge
T1	Conception du modèle multidimensionnel	Conception	Haute	3 j
T2	Création de la base PostgreSQL orange_dwh	Infrastructure	Haute	1 j
T3	Implémentation des 7 tables de dimensions	DWH	Haute	2 j
T4	Implémentation des 2 tables de faits	DWH	Haute	2 j
T5	Développement du module d'extraction (E)	ETL	Haute	3 j
T6	Développement du module de transformation (T)	ETL	Haute	4 j
T7	Développement du module de chargement (L)	ETL	Haute	2 j
T8	Module de Data Quality (détection d'anomalies)	Qualité	Haute	3 j
T9	Création des requêtes SQL d'analyse	DWH	Moyenne	2 j
T10	Validation visuelle sous pgAdmin	Validation	Moyenne	1 j

Table 3.1 – Sprint Backlog du Sprint 2 — Réalisation du DWH et de l'ETL

À l'issue du sprint, l'ensemble des tâches a été livré et validé lors de la *Sprint Review* avec le maître de stage. La figure 3.1 présente une synthèse visuelle des principaux livrables obtenus : la base de données orange_dwh, les tables dimensionnelles et factuelles, le pipeline ETL Python, le module de contrôle de la qualité des données ainsi que les requêtes SQL d'analyse.




Figure 3.1 – Synthèse visuelle des livrables du Sprint 2

3.2 Analyse Exploratoire des Données

3.2.1 Présentation des données sources

Les données sources mobilisées pour ce projet proviennent de huit fichiers extraits des systèmes opérationnels d'Orange Tunisie. Ces fichiers couvrent l'ensemble du périmètre commercial nécessaire à la mise en place de l'entrepôt décisionnel.

Source	Contenu	Volume
ventes_contrats.xlsx	Souscriptions des contrats à facture	105 088 lignes
vendeurs.xlsx	Référentiel des vendeurs	22 001 lignes
boutiques.xlsx	Référentiel des entités commerciales	3 168 lignes
offres.xlsx	Catalogue des offres commerciales	32 lignes
groupes.xlsx	Groupes de produits	18 lignes
articles.xlsx	Catalogue produits	47 lignes
ref_objectifs.xlsx	Référentiel des objectifs	12 lignes
objectifs.xlsx	Objectifs commerciaux mensuels	2 045 lignes

Table 3.2 – Présentation des sources de données du projet

3.2.2 Analyse univariée

L'analyse univariée examine la distribution individuelle des variables clés afin de détecter les concentrations, les valeurs atypiques et les éventuels biais.

Répartition des ventes par canal. La table `ventes_contrats` révèle une forte concentration sur trois canaux principaux : FRANCHISE (51,0 %), BTQ (29,1 %) et LAB2.0 (14,9 %). Les autres canaux (PDV LAB, PDV EXP, PDV ADSL, PRO_VI, PDV TRADE, DISTRIBUTEUR, TRE) cumulent moins de 5 % des souscriptions.



Figure 3.2 – Distribution des ventes par canal de vente

Distribution des durées d'engagement. La durée d'engagement moyenne s'établit à 17,9 mois, avec un pic à 24 mois correspondant aux contrats post-payés standards. Des durées de 12 mois et 36 mois apparaissent comme valeurs secondaires.



Figure 3.3 – Histogramme des durées d'engagement des contrats

Top offres commerciales. Cinq offres représentent l'essentiel des souscriptions : TOP DU TOP (4 435), MAXBOX 5G (2 768), FLYBOX 4G POST PAYÉE (2 526), FIBRE (370) et FORFAIT INTERNET 4G (367).

3.2.3 Analyse bivariée

L'analyse bivariée explore les relations entre paires de variables afin d'identifier les corrélations utiles pour la modélisation multidimensionnelle ultérieure.

Canal × Taux de paiement. Le croisement révèle des écarts significatifs : les canaux PRO_VI et PDV ADSL affichent les meilleurs taux de paiement ($> 95\%$), tandis que les canaux BTQ et DISTRIBUTEUR présentent les taux d'impayés les plus élevés.

Mois × Réalisation des objectifs. L'évolution mensuelle de novembre 2024 à mars 2025 montre un taux de réalisation global qui oscille entre 36% et 42% , avec une moyenne consolidée de $39,66\%$ — chiffre central du diagnostic métier.



Figure 3.4 – Croisement canal × mois — taux de réalisation des objectifs

Conclusion de l'EDA. L'analyse exploratoire confirme la pertinence d'une modélisation en constellation avec deux faits distincts (ventes, objectifs) reliés à des dimensions partagées (boutique, date), ce qui sera détaillé dans la section suivante.

3.3 Conception Multidimensionnelle

3.3.1 Choix de l'approche

Approche Inmon

L'approche Inmon, proposée par Bill Inmon, consiste à construire d'abord un entrepôt central normalisé (3NF) regroupant l'ensemble des données de l'entreprise, puis à en dériver des data marts thématiques destinés aux différents métiers.

Approche Kimball

L'approche Kimball, défendue par Ralph Kimball, repose sur la construction directe de data marts dimensionnels orientés métier, qui s'agrègent progressivement pour former l'entrepôt complet.

Comparaison et choix

Critère	Inmon	Kimball
Approche	Top-down (entrepôt puis data marts)	Bottom-up (data marts puis entrepôt)
Modélisation	Normalisée (3NF)	Dimensionnelle (faits/dimensions)
Délai de mise en œuvre	Long	Court
Coût initial	Élevé	Maîtrisé
Compatibilité BI native	Moyenne	Excellente
Adapté à la durée du stage	Non	Oui

Table 3.3 – Comparaison entre les approches Inmon et Kimball

L'approche **Kimball** a été retenue pour ce projet en raison de sa rapidité de mise en œuvre compatible avec la durée du stage, de son orientation métier directe et de sa compatibilité native avec les outils de reporting tels que Power BI utilisé dans la maquette comparative.

3.3.2 Choix du schéma conceptuel

Schéma en étoile

Modèle le plus simple : une seule table de faits centrale entourée de plusieurs tables de dimensions dénormalisées. Performant en lecture mais limité à un seul processus métier.

Schéma en flocon

Variante normalisée du schéma en étoile où les dimensions sont décomposées en sous-dimensions. Réduit la redondance mais complexifie les requêtes et dégrade les performances.

Schéma en constellation

Plusieurs tables de faits partagent des dimensions communes. Adapté aux projets multi-processus où plusieurs sujets d'analyse coexistent.

Comparaison et choix

Critère	Étoile	Flocon	Constellation
Nombre de faits	1	1	2 ou plus
Dimensions	Dénormalisées	Normalisées	Partagées entre faits
Performance	Excellente	Moyenne	Bonne
Lisibilité métier	Élevée	Faible	Élevée
Adapté au projet	Non (2 faits)	Non	Oui

Table 3.4 – Comparaison des schémas dimensionnels

Le schéma en **constellation** a été retenu : il permet à nos deux tables de faits (fact_ventes et fact_objectifs) de partager la dimension dim_boutique, garantissant la cohérence des analyses transverses ventes vs objectifs.

3.3.3 Tables de dimensions

Le tableau 3.5 détaille la structure des sept tables de dimensions du Data Warehouse.

Dimension	Volume	Attributs principaux
dim_date	3 653 lignes	date_key, date_valeur, annee, trimestre, mois, jour_mois, est_weekend, est_ferie, semestre
dim_vendeur	1 351 lignes	vendeur_key, seller_id, seller_name, code_stock, month, seller_key_composite
dim_boutique	379 lignes	boutique_key, entity_code, entity_name, responsable, canal_vente, region
dim_produit	47 lignes	produit_key, product_code, product_name, product_type, famille_produit
dim_offre	32 lignes	offre_key, tmcode, offre_name, type_offre, canal
dim_groupe	18 lignes	groupe_key, prgcode, prgname, famille
dim_ref_objectifs	12 lignes	ref_obj_key, ligne_pdt_obj, designation

Table 3.5 – Détail des tables de dimensions

L'extrait suivant illustre la création de la dimension vendeur sous PostgreSQL.

The screenshot shows a PostgreSQL query editor with the following SQL query:

```
1 SELECT * FROM dim_vendeur LIMIT 10;
```

Below the query editor, the 'Data Output' tab displays the results of the query. The table has 7 columns: vendeur_key [PK] integer, seller_id character varying (50), seller_name character varying (255), code_stock character varying (50), month character varying (7), and seller_key_composite character varying (100). The results show 10 rows of data.

	vendeur_key [PK] integer	seller_id character varying (50)	seller_name character varying (255)	code_stock character varying (50)	month character varying (7)	seller_key_composite character varying (100)
1	66004	STDGAT	STE DIGITAL GATE	MAH0061	2024-11	STDGAT_2024-11
2	66005	BOUCYOS	Yosra Bouchiba1	FAL0032F	2024-11	BOUCYOS_2024-11
3	66006	OUGARC	OUGARC	BEN0159L	2024-11	OUGARC_2024-11
4	66007	CYBRNT	CYBERNET	MAN0119	2024-11	CYBRNT_2024-11
5	66008	BISTRE	BI STORE+	ARI0183	2024-11	BISTRE_2024-11
6	66009	YMONTAC	MONTASSAR YOUNSI	TUN0060L	2024-11	YMONTAC_2024-11
7	66010	KDRID	Kenza Dridi	LAC0012F	2024-11	KDRID_2024-11
8	66011	ONCLIC	ONECLICK	GAF0063	2024-11	ONCLIC_2024-11
9	66012	NRMI	Rami Naouali	MSK0013F	2024-11	NRMI_2024-11
10	66013	TECHME	TECHNOLOGY HOME	SIL0001	2024-11	TECHME_2024-11

At the bottom of the table, it indicates 'Total rows: 10' and 'Query complete 00:00:00.180'. The status bar shows 'CRLF' and 'Ln 1, Col 36'.

Figure 3.5 – Création de la table dim_vendeur sous PostgreSQL

Cette capture présente la structure SQL de la dimension vendeur, utilisée pour analyser les performances commerciales par vendeur.

3.3.4 Tables de faits

Les deux tables de faits constituent le cœur analytique du Data Warehouse. Elles enregistrent les événements mesurables (ventes, objectifs) et référencent les dimensions via leurs clés étrangères.

Table fact_ventes

Cette table contient l'ensemble des ventes journalières des contrats à facture. Sa granularité est définie au niveau *contrat — vendeur — jour*. Elle intègre également le **suivi des paiements** via trois colonnes dédiées (*first_month_bill*, *second_month_bill*, *third_month_bill*) permettant de tracer le règlement des trois premières factures mensuelles de chaque contrat.

Query Query History

```
1 SELECT * FROM fact_ventes LIMIT 10;
```

Scratch Pad

Data Output Messages Notifications

Showing rows: 1 to 10 Page No: 1 of 1

	ventes_id [PK] integer	vendeur_key integer	boutique_key integer	produit_key integer	offre_key integer	groupe_key integer	date_vente date	contrat_souscrit integer	duree_engagement integer	first_month_bill smallint	second_month_bill smallint
1	352105	68440	3433	[null]	515	80	2024-12-16	[null]	0	[null]	
2	352187	73230	3434	[null]	515	80	2024-12-16	[null]	0	[null]	
3	352594	66451	5678	[null]	515	80	2024-12-17	[null]	0	[null]	
4	353514	74809	3362	[null]	515	80	2024-12-21	[null]	0	[null]	
5	353562	74822	3362	[null]	515	80	2024-12-11	[null]	0	[null]	
6	354152	67565	3368	[null]	381	80	2024-12-27	[null]	24	[null]	
7	355204	69318	3589	[null]	515	80	2024-12-23	[null]	0	[null]	
8	355678	76237	[null]	[null]	409	100	2024-12-06	[null]	12	[null]	
9	357662	72202	5074	[null]	515	80	2025-01-16	[null]	0	[null]	
10	358209	67347	3921	[null]	515	80	2025-02-12	[null]	0	[null]	

Total rows: 10 Query complete 00:00:00.680 CRLF Ln 1, Col 36

Figure 3.6 – Création de la table fact_ventes sous PostgreSQL

Cette capture montre la table de faits centrale des ventes, qui regroupe les mesures nécessaires au pilotage commercial.

Avec 63 615 contrats vendus, cette table constitue la principale source d'analyse pour l'ensemble des indicateurs commerciaux du projet : top vendeurs, top boutiques, répartition par canal, performance par offre, et taux de paiement de la première facture (89,84 % sur l'historique étudié).

Table fact_objectifs

Cette table assure le suivi des **objectifs commerciaux mensuels** fixés à chaque boutique selon la ligne de produit. Elle permet notamment de calculer le **taux de réalisation des objectifs** (39,66 % sur la période étudiée), indicateur clé pour le pilotage commercial. Elle partage la dimension dim_boutique avec fact_ventes, ce qui matérialise le schéma en constellation et garantit la cohérence des analyses transverses « ventes vs objectifs ».

Query Query History

```
1 SELECT * FROM fact_objectifs LIMIT 10;
```

Data Output Messages Notifications

Showing rows: 1 to 10

	objectif_id [PK] integer	boutique_key integer	ref_obj_key integer	date_objectif date	mois_objectif character varying (7)	montant_objectif numeric (15,2)
1	1409	4694	23	[null]	[null]	21.00
2	1410	3435	23	[null]	[null]	195.00
3	1411	4658	23	[null]	[null]	7.00
4	1412	5927	23	[null]	[null]	1.00
5	1413	3352	23	[null]	[null]	5.00
6	1414	3589	23	[null]	[null]	9.00
7	1415	3593	23	[null]	[null]	6.00
8	1416	3239	23	[null]	[null]	27.00
9	1417	3441	23	[null]	[null]	60.00
10	1418	5909	23	[null]	[null]	2.00

Total rows: 10 Query complete 00:00:02.626

Figure 3.7 – Création de la table fact_objectifs

Cette capture décrit la table de faits des objectifs, utilisée pour comparer les réalisations aux cibles commerciales fixées.

3.3.5 Schéma final

L'entrepôt orange_dwh ainsi conçu est composé de neuf tables : sept dimensions et deux faits. La figure 3.8 présente le schéma en constellation final.




Figure 3.8 – Schéma en constellation du Data Warehouse orange_dwh

Conclusion

Au terme de ce chapitre, l'architecture multidimensionnelle de l'entrepôt orange_dwh a été entièrement définie. L'analyse exploratoire a confirmé la pertinence d'une modélisation en constellation, validée par la comparaison méthodique des approches et des schémas disponibles. Le chapitre suivant détaille la mise en œuvre du processus ETL qui alimentera physiquement cet entrepôt.

Chapitre 4

Processus ETL

Plan

- 4.1 Sprint Backlog du Sprint 3
- 4.2 Présentation du Processus ETL
- 4.3 Environnement Technologique
- 4.4 Réalisation de l'ETL
- 4.5 Visualisation sur pgAdmin
- 4.6 Conclusion

Introduction

Après avoir défini la structure cible du Data Warehouse au chapitre précédent, ce quatrième chapitre est consacré à sa mise en œuvre physique à travers le pipeline ETL (*Extract, Transform, Load*). Ce pipeline assure la transformation des données opérationnelles hétérogènes en informations cohérentes, fiables et exploitables.

4.1 Sprint Backlog du Sprint 3

Le Sprint 3 a pour objectif principal : « *Développer un pipeline ETL automatisé en Python capable de traiter les huit sources opérationnelles et d'alimenter le Data Warehouse orange_dwh avec un haut niveau de fiabilité* ».

ID	Tâche	Priorité	Charge
T1	Module d'extraction des 8 sources	Haute	3 j
T2	Module de transformation et nettoyage	Haute	4 j
T3	Module de chargement vers PostgreSQL	Haute	2 j
T4	Tests de cohérence post-charge	Haute	1 j
T5	Visualisation et validation sous pgAdmin	Moyenne	1 j

Table 4.1 – Sprint Backlog du Sprint 3 — Processus ETL

4.2 Présentation du Processus ETL

Un processus ETL automatise la circulation des données depuis les sources opérationnelles jusqu'à l'entrepôt analytique en trois phases successives :

- **Extraction (E)** : collecte des données depuis les fichiers sources Excel et CSV ;
- **Transformation (T)** : nettoyage, harmonisation, enrichissement et application des règles métier ;
- **Chargement (L)** : insertion sécurisée dans le Data Warehouse PostgreSQL.




Figure 4.1 – Architecture du processus ETL en Python

4.3 Environnement Technologique

4.3.1 Comparaison des outils ETL

Plusieurs outils sont disponibles pour l'implémentation d'un pipeline ETL, allant des solutions graphiques complètes aux bibliothèques de programmation.

Critère	Python (pandas)	Talend Open Studio	Pentaho Kettle
Licence	Open source	Open source	Open source
Interface	Code	Graphique	Graphique
Souplesse	Très élevée	Moyenne	Moyenne
Intégration ML	Native	Limitée	Limitée
Communauté Data Science	Très forte	Bonne	Limitée
Adapté au projet	Oui	Non	Non

Table 4.2 – Comparaison des outils ETL évalués

Python (pandas + SQLAlchemy + psycopg2) a été retenu pour sa souplesse, sa compatibilité native avec les modèles de Machine Learning et la maîtrise préalable du langage.

4.3.2 Comparaison des SGBD

Critère	PostgreSQL	MySQL	SQL Server	Oracle
Licence	Open source	Open source	Propriétaire	Propriétaire
Coût	Gratuit	Gratuit	Élevé	Très élevé
Conformité SQL	Excellente	Bonne	Très bonne	Excellente
Types avancés	JSON, géométrie	Limité	Bons	Excellents
Adapté projet	Oui	Partiel	Non (licence)	Non (licence)

Table 4.3 – Comparaison des SGBD candidats

PostgreSQL 17 a été retenu : open source, robuste, parfaitement adapté aux workloads analytiques.

4.4 Réalisation de l'ETL

4.4.1 Module d'Extraction

La phase d'extraction consiste à collecter les données depuis les sources opérationnelles d'Orange Tunisie. Au total, 132 411 lignes ont été extraites depuis les fichiers sources.

```
def process_table(table_name: str, table_config: dict) -> dict:
    """Traite une seule table de bout en bout."""
    logger = setup_logger(table_name)

    source = table_config["source_file"]
    output = table_config["output_file"]

    # 1. Chargement
    logger.info(f"Chargement: {source}")
    df = pd.read_excel(source)
    logger.info(f"Charge: {df.shape[0]:,} lignes x {df.shape[1]} colonnes")
```

Figure 4.2 – Extrait du module d'extraction

4.4.2 Module de Transformation

La phase de transformation est l'étape la plus complexe du pipeline. Elle a pour objectif de **nettoyer**, **harmoniser** et **enrichir** les données extraites avant leur chargement dans le Data Warehouse. Les principales opérations réalisées sont les suivantes :

Nettoyage des données

- suppression des **doublons** sur les clés métiers;
- traitement des **valeurs manquantes** (*nulls*) par imputation ou suppression contextuelle;
- correction des **formats de date** hétérogènes;
- normalisation des **libellés** (mise en majuscules, suppression des espaces parasites).

Harmonisation et standardisation

- uniformisation des codes des canaux de vente (FRANCHISE, PROPRE);
- rapprochement des codes vendeurs avec le référentiel officiel;
- conversion des montants en une devise unique.

Enrichissement des données

- ajout de la dimension temporelle (jour, mois, trimestre, année, jour férié);

- calcul des indicateurs dérivés (taux de réalisation, ratio paiement);
- attribution des clés étrangères pointant vers les dimensions du DWH.

```
# Ordre optimal des etapes
df = self.rename_columns(df)
df = self.clean_strings(df)
df = self.standardize_categories(df)
df = self.parse_dates(df)
df = self.add_month_column(df)
df = self.convert_numerics(df)
df = self.drop_null_rows(df)
df = self.add_composite_key(df)
df = self.drop_duplicates(df)
df = self.apply_conditional_fills(df)
df = self.fill_missing(df)
df = self.apply_output_types(df)
```

Figure 4.3 – Module de transformation ETL

Cette capture met en évidence les traitements de nettoyage et d'harmonisation appliqués avant le chargement dans l'entrepôt.

À l'issue de la phase de transformation, sur les 132 411 lignes extraites, **90 696 enregistrements valides** ont été retenus pour le chargement dans le Data Warehouse. La différence (41 715 lignes) correspond aux doublons et aux enregistrements invalides identifiés par le module de Data Quality.

4.4.3 Module de Chargement

La phase de chargement insère les données transformées dans les tables du Data Warehouse PostgreSQL via SQLAlchemy.

```
insert_mode = "append" if table_exists else "replace"
nb_inserted = write_to_dwh(df_prepared, dwh_table, if_exists=insert_mode)

# 5. Verifier
nb_in_db = count_rows(dwh_table)
print(f"Lignes dans la BD : {nb_in_db}")

return nb_inserted
```

Figure 4.4 – Extrait du module de chargement

Deux stratégies sont mises en œuvre : chargement complet pour les dimensions, chargement incrémental pour les faits.

4.4.4 Module de Data Quality

Au-delà du pipeline ETL classique, un **module de contrôle de la qualité des données** a été développé en parallèle. Ce module applique cinq familles de contrôles automatisés sur les données extraites avant leur chargement définitif :

- **Détection des doublons** : identification des lignes strictement identiques répétées dans les sources ;
- **Contrôle de complétude** : recensement des champs obligatoires non renseignés ;
- **Validation des formats** : vérification des dates, des montants numériques, des codes d'identification ;
- **Contrôle d'intégrité référentielle** : détection des références à des vendeurs ou boutiques inexistants ;
- **Détection de valeurs aberrantes** : montants négatifs, durées d'engagement invraisemblables.

L'exécution de ce module sur les 132 411 lignes extraites a permis d'identifier **44 537 anomalies**, soit un taux de validité de 68,49 %. Ces anomalies sont consignées dans des rapports détaillés qui seront exploités par l'interface dédiée présentée au chapitre 6.




Figure 4.5 – Pipeline du module Data Quality au sein de l'ETL

Cette figure présente l'exécution du pipeline ETL et du module Data Quality. Le processus traite automatiquement les différentes tables sources, applique les opérations de nettoyage et de validation des données, puis génère les fichiers nettoyés ainsi que les rapports de qualité associés. Le récapitulatif permet de vérifier le volume de données traité, les lignes extraites, les enregistrements supprimés et les livrables produits pour chaque table.

4.5 Visualisation sur pgAdmin

Le contrôle visuel des chargements est effectué via pgAdmin 4. Les résultats obtenus montrent que la table `fact_ventes` contient **63 615 enregistrements** chargés avec succès. Des contrôles complémentaires ont été réalisés sur les tables dimensionnelles afin de garantir la cohérence des clés et l'intégrité des relations.




Figure 4.6 – Vue d'ensemble du Data Warehouse orange_dwh sous pgAdmin 4

Cette figure présente l'implémentation physique du Data Warehouse orange_dwh dans PostgreSQL à travers l'outil pgAdmin 4. Elle met en évidence l'organisation des tables de dimensions et des tables de faits constituant le schéma décisionnel utilisé pour l'analyse des ventes, le suivi des objectifs commerciaux et l'entraînement des modèles de Machine Learning.

Conclusion

Ce chapitre a présenté la mise en œuvre du pipeline ETL en Python qui alimente le Data Warehouse orange_dwh. Sur les 132 411 lignes extraites des huit sources opérationnelles, 90 696 enregistrements valides ont été chargés. L'entrepôt étant désormais opérationnel, le chapitre suivant exploite ces données pour le développement des modèles prédictifs et des tableaux de bord.

Chapitre 5

Application Web et Reporting

Plan

- 5.1 Sprint Backlog du Sprint 4
- 5.2 Modélisation Machine Learning
- 5.3 Architecture de l'application Flask
- 5.4 Authentification et gestion des utilisateurs
- 5.5 Tableaux de bord interactifs
- 5.6 Chatbot analytique ORYA
- 5.7 Maquette comparative Power BI
- 5.8 Conclusion

Introduction

Après la conception du Data Warehouse et la mise en œuvre du processus ETL, ce chapitre est dédié à la réalisation de l'**application web** et à l'intégration des modèles de Machine Learning qui alimentent la plateforme décisionnelle. Cette application met à disposition des équipes de la Direction Commerciale d'Orange Tunisie l'ensemble des fonctionnalités attendues : authentification sécurisée, tableaux de bord interactifs, prédictions issues des modèles ML et un assistant conversationnel intelligent capable de répondre en langage naturel. Le chapitre se conclut par la présentation d'une maquette comparative développée sous Power BI.

5.1 Sprint Backlog du Sprint 4

Le Sprint 4 a pour objectif principal : « *Développer l'application Flask intégrant l'authentification, les quatre tableaux de bord interactifs et le chatbot ORYA, et préparer la maquette comparative Power BI* ».

ID	Tâche	Priorité	Charge
T1	Mise en place de l'architecture Flask (MVC, Blueprints)	Haute	1 j
T2	Module d'authentification (flask-login)	Haute	2 j
T3	Tableau de bord <i>Performance</i>	Haute	2 j
T4	Tableau de bord <i>Objectifs</i>	Haute	2 j
T5	Tableau de bord <i>Prediction</i>	Haute	2 j
T6	Tableau de bord <i>Paielements</i>	Haute	2 j
T7	Intégration du chatbot ORYA (API Google Gemini)	Haute	3 j
T8	Maquette comparative sous Power BI Desktop	Moyenne	2 j

Table 5.1 – Sprint Backlog du Sprint 4 – Application Web et Reporting

5.2 Modélisation Machine Learning

Cette section présente la conception, l'entraînement et l'évaluation des cinq modèles de Machine Learning intégrés à la plateforme : segmentation des vendeurs, détection d'anomalies, régression, forecasting de clôture mensuelle et classification du paiement de la première facture.

5.2.1 Approche méthodologique

Vue d'ensemble

La modélisation est organisée en six notebooks Jupyter indépendants, chacun dédié à un objectif analytique précis. Cette séparation est conforme à la décision méthodologique prise au chapitre 1 : refuser une approche CRISP-DM globale et associer chaque modèle à son propre sprint d'évaluation. Les notebooks sont les suivants :

- **Notebook 01** – Analyse exploratoire des données (EDA) ;
- **Notebook 02** – Segmentation des vendeurs par *clustering* ;

- **Notebook 03** – Détection d'anomalies ;
- **Notebook 04** – Régression et prédiction des ventes ;
- **Notebook 05** – *Forecasting* de clôture mensuelle ;
- **Notebook 06** – Classification du paiement de la première facture.

Préparation commune des données

L'ensemble des modèles s'alimente directement depuis l'entrepôt `orange_dwh` construit au chapitre 3. Les données sont chargées via la bibliothèque `pandas` à partir de requêtes SQL ciblées, puis pré-traitées selon les besoins spécifiques de chaque algorithme : normalisation (`StandardScaler`), encodage des variables catégorielles (`OneHotEncoder`), traitement des valeurs manquantes, et découpage temporel pour la validation croisée.




Figure 5.1 – Workflow général de modélisation Machine Learning

2. Analyse des Ventes (fact_ventes)

La table principale contient 63 615 contrats de vente.

```
# === CHARGEMENT DE FACT_VENTES ===
df_ventes = pd.read_sql("SELECT * FROM fact_ventes", engine)

print(f"Dimensions : {df_ventes.shape}")
print(f"Colonnes ({len(df_ventes.columns)}) : {list(df_ventes.columns)}\n")

df_ventes.head()
```

Dimensions : (63615, 14)
 Colonnes (14) : ['ventes_id', 'vendeur_key', 'boutique_key', 'produit_key', 'offre_key', 'groupe_key', 'date_vente', 'contrat_souscrit', 'duree_engagement', 'first_month_bill', 'second_month_bill', 'third_month_bill', 'product_number', 'date_creation']

	ventes_id	vendeur_key	boutique_key	produit_key	offre_key	groupe_key	date_vente	contrat_souscrit	duree_engagement	first_month_bill	second_month_bill	third_month_bill
0	335635	75350	3437.0	None	512.0	101	2025-02-10	None	25	1.0	1.0	1.0
1	335636	68181	5673.0	None	392.0	80	2025-02-06	None	24	1.0	1.0	1.0
2	335637	78393	5680.0	None	428.0	100	2025-02-25	None	24	1.0	1.0	1.0
3	335638	68376	3440.0	None	512.0	101	2025-02-15	None	25	1.0	1.0	1.0
4	335639	74817	3432.0	None	379.0	80	2025-03-11	None	24	1.0	1.0	1.0

Figure 5.2 – Chargement et préparation des données depuis le DWH

5.2.2 Clustering des vendeurs

Objectif métier

La Direction Commerciale d'Orange Tunisie souhaitait disposer d'une typologie claire de ses 1 351 vendeurs afin de personnaliser les actions de pilotage : valoriser les meilleurs vendeurs, accompagner les profils intermédiaires, et identifier les vendeurs en difficulté nécessitant un plan de remontée. Un algorithme non supervisé de *clustering* a été retenu pour structurer cette segmentation à partir des données historiques de vente.

Choix de l'algorithme

Trois algorithmes de *clustering* ont été comparés sur le jeu de données vendeurs.

Critère	K-Means	Hierarchical	DBSCAN
Forme des clusters	Sphérique	Hiérarchique	Densité
Nombre de clusters	À fixer	Dendrogramme	Automatique
Passage à l'échelle	Très bon	Limité ($O(n^2)$)	Moyen
Sensibilité aux outliers	Forte	Forte	Faible
Interprétabilité métier	Élevée	Élevée	Limitée
Adapté au cas d'usage	Oui	Partiellement	Non

Table 5.2 – Comparaison des algorithmes de *clustering*

Le choix s'est porté sur **K-Means** en raison de sa simplicité de mise en œuvre, de son passage à l'échelle, et surtout de la lisibilité métier de ses résultats : chaque *cluster* est représenté par un centroïde directement interprétable comme un « profil type » de vendeur.

Détermination du nombre optimal de clusters

Le nombre k optimal de *clusters* a été déterminé par deux méthodes complémentaires : la **méthode du coude** (*elbow method*) sur l'inertie intra-*cluster* et le **score de silhouette**. Les deux méthodes convergent vers $k = 3$.




Figure 5.3 – Choix du nombre optimal de clusters : méthode du coude et silhouette

```

K-Means termine !

Nombre de vendeurs par cluster :
cluster
0      1036
1       46
2      269
Name: count, dtype: int64

CARACTERISTIQUES DES CLUSTERS
=====
      Ventes_moy  CA_moy  Panier_moy  Nb_vendeurs
cluster
2          127.72   114.03         0.95         269
0          27.96    25.50         0.96        1036
1           6.28     7.00         0.20         46
  
```

Figure 5.4 – Entraînement du modèle K-Means

Les vendeurs se répartissent en trois segments distincts : performants (cluster 2), intermédiaires (cluster 0), et à faible activité (cluster 1).

Résultats et personas identifiés

L'application de K-Means avec $k = 3$ aboutit à trois *clusters* distincts, que nous avons baptisés **TOP**, **RÉGULIERS** et **EN DIFFICULTÉ**. Le score de silhouette obtenu est de **0,452**, valeur jugée satisfaisante au regard de l'hétérogénéité naturelle de la population des vendeurs.

Persona	Effectif	Profil
TOP	269	Volume de ventes élevé, taux de paiement très bon, ancienneté solide
RÉGULIERS	1 036	Performance stable et conforme aux objectifs
EN DIFFICULTÉ	46	Faible volume, taux de paiement dégradé, profil prioritaire pour accompagnement


Table 5.3 – Personas vendeurs issus du *clustering* K-Means

Figure 5.5 – Répartition des vendeurs selon les clusters identifiés

Interprétation métier

Le *cluster* **TOP** (269 vendeurs) représente l'élite commerciale d'Orange Tunisie. Le *cluster* **EN DIFFICULTÉ** (46 vendeurs), bien que minoritaire, constitue une cible d'attention prioritaire pour la Direction Commerciale : un plan d'accompagnement ciblé sur ces profils permettrait, à effort modéré, de relever significativement la performance globale. Le *cluster* **RÉGULIERS** (1 036 vendeurs) constitue le socle stable de l'activité.

5.2.3 Détection d'anomalies

Objectif

La détection d'anomalies vise à identifier automatiquement, dans les ventes et les paiements, les enregistrements présentant un comportement statistiquement atypique (fraudes potentielles, erreurs de saisie, anomalies métier réelles). Ce dispositif complète le module de

Data Quality du chapitre 3 en s'appuyant sur des techniques non supervisées de Machine Learning.

Comparaison des algorithmes

Cinq algorithmes ont été évalués sur le même jeu de validation.

Algorithme	Précision	Rappel	F1-score	Remarque
Isolation Forest	0,82	0,76	0,79	Rapide, robuste, peu sensible aux hyperparamètres
One-Class SVM	0,75	0,71	0,73	Sensible au choix du noyau
DBSCAN	0,68	0,82	0,74	Bon rappel mais sur-détection
Auto-encoder	0,77	0,74	0,75	Coût d'entraînement élevé
GAN (AnoGAN)	0,71	0,69	0,70	Instabilité d'entraînement

Table 5.4 – Comparaison des algorithmes de détection d'anomalies




Figure 5.6 – Comparaison des algorithmes de détection d'anomalies

Cette figure compare les performances des différents algorithmes de détection d'anomalies testés. Isolation Forest identifie 47 anomalies (3,5 %), tandis que One-Class SVM détecte 126 anomalies (9,3 %). Les résultats obtenus permettent d'évaluer la sensibilité de chaque approche face aux comportements atypiques.

```
Entrainement GAN (approximation)...  
Cela peut prendre 2-3 minutes...  
Termine !  
Score GAN moyen : 0.626  
Seuil GAN : 0.598  
Anomalies detectees : 68 (5.0%)
```

Figure 5.7 – Résultats de la détection d'anomalies par GAN

Cette capture présente les résultats obtenus avec l'approche GAN pour la détection d'anomalies. Le modèle a identifié 68 observations atypiques, représentant environ 5 % des 1 351 vendeurs analysés. Les scores générés permettent de distinguer les comportements normaux des profils potentiellement anormaux.

Algorithme retenu : Isolation Forest

Isolation Forest a été retenu pour son meilleur compromis précision/rappel, sa robustesse face aux hyperparamètres et sa rapidité d'inférence, propriété essentielle pour une intégration en production dans l'application Flask.

```
Entrainement Isolation Forest...  
Termine !  
Anomalies detectees : 47 (3.5%)
```

Figure 5.8 – Détection d'anomalies par Isolation Forest

Cette capture présente le résultat de l'exécution du modèle Isolation Forest. L'algorithme a identifié 47 observations atypiques, représentant 3,5 % de l'ensemble des vendeurs analysés. Ces anomalies correspondent à des comportements commerciaux inhabituels nécessitant une investigation complémentaire.

Résultats

Sur l'ensemble des **1 351 vendeurs** analysés, le modèle Isolation Forest a identifié **47 vendeurs atypiques** (3,5 % de la population, paramètre `contamination` = 0.05). Une analyse approfondie de ces anomalies a permis de mettre en évidence des profils présentant des combinaisons inhabituelles de variables : nombre de ventes anormalement élevé pour la durée d'activité, panier moyen incohérent avec le canal d'affectation, ou taux de paiement de seconde facture significativement dégradé. Ces vendeurs ont été remontés à la Direction Commerciale pour investigation manuelle.

```

CONSENSUS DES ALGORITHMES
=====
Detecte par 0/5 algos : 1142 vendeurs (84.5%)
Detecte par 1/5 algos : 117 vendeurs (8.7%)
Detecte par 2/5 algos : 58 vendeurs (4.3%)
Detecte par 3/5 algos : 12 vendeurs (0.9%)
Detecte par 4/5 algos : 15 vendeurs (1.1%)
Detecte par 5/5 algos : 7 vendeurs (0.5%)

Anomalies HAUTE CONFIANCE (>=3 algos) : 34

TOP 10 ANOMALIES (selon consensus)
=====

```

	vendeur	nb_ventes	ca_total	panier_moyen	nb_detections
929	MARIEM MAGROUN	339	321.0	0.96	5
1247	SANA AYEYDA	348	303.0	0.88	5
835	ILEF MAKHLOUFA	249	199.0	0.98	5
743	MARWENE BELAAIBA	452	376.0	0.87	5
818	YOSRA ELKAMEL	323	271.0	0.88	5
407	ONS GANNOUN	265	222.0	0.99	5
382	AYOUB ABOUDI	353	272.0	0.95	5
137	NIZAR AISSA	207	194.0	0.98	4
915	ROUKAIA BEN ABADALH	207	143.0	0.71	4
694	Manel Jaafra	253	225.0	0.89	4

Figure 5.9 – Consensus des anomalies détectées par les algorithmes

Cette figure présente le niveau de consensus entre les cinq algorithmes de détection d'anomalies testés. Les observations détectées simultanément par plusieurs méthodes sont considérées comme des anomalies à haute confiance. Les résultats mettent également en évidence les vendeurs les plus fréquemment identifiés comme atypiques et nécessitant une analyse métier approfondie.

5.2.4 Régression et prédiction des ventes

Objectif

La régression vise à prédire le **nombre de ventes** qu'un vendeur ou une boutique réalisera sur un horizon donné, à partir de ses caractéristiques (canal, région, ancienneté, performance historique). Ce modèle vient en appui des prévisions d'objectifs et de l'allocation des ressources commerciales.

Comparaison des algorithmes

Sept algorithmes de régression ont été évalués par validation croisée à cinq plis.

Algorithme	R^2	Observation
Régression linéaire	0,024	Baseline simple
SVM (RBF)	-0,050	Inadapté au cas d'usage
Decision Tree	0,088	Surapprentissage
XGBoost	0,072	Complexité non rentable
Random Forest	0,127	Bonne robustesse
ANN (Deep Learning)	0,068	Données insuffisantes
KNN (GridSearchCV)	0,141	Meilleur compromis

Table 5.5 – Comparaison des algorithmes de régression

Algorithme retenu : KNN

Les résultats obtenus montrent que la **prédiction du nombre de ventes par vendeur** reste un problème difficile au vu des variables explicatives disponibles dans le Data Warehouse (canal, boutique, région). Les scores R^2 relativement bas confirment que la performance d'un vendeur dépend également de facteurs comportementaux non capturés dans les attributs catégoriels. **KNN (avec GridSearchCV)** obtient toutefois le meilleur compromis avec un $R^2 = 0,141$ sur le jeu de test. Cette performance, bien que modeste, fournit une première baseline exploitable. Une amélioration future consisterait à enrichir les features avec des variables comportementales (ancienneté du vendeur, taux de paiement historique, diversité des offres vendues).

Comparaison globale des algorithmes

La figure 5.10 compare les performances des sept algorithmes de régression évalués dans le cadre de la prédiction des ventes. Les modèles sont comparés selon quatre indicateurs : le coefficient de détermination (R^2), l'erreur absolue moyenne (MAE), la racine de l'erreur quadratique moyenne (RMSE) et le temps d'exécution. Les résultats confirment que KNN (avec GridSearchCV) obtient le meilleur score R^2 (0,141), suivi des modèles à arbres (Random Forest, XGBoost) qui offrent un compromis acceptable entre qualité de prédiction et temps de calcul.




Figure 5.10 – Comparaison des performances des algorithmes de régression

5.2.5 Forecasting de clôture mensuelle

Objectif

Le *forecasting* de clôture mensuelle constitue l'un des modèles les plus stratégiques de la plateforme. Son objectif : prédire, à chaque jour du mois, le volume de ventes attendu en fin de période, et permettre ainsi à la Direction Commerciale d'anticiper l'atteinte ou non des objectifs.

Comparaison des algorithmes

Huit modèles de prévision temporelle ont été comparés. La métrique principale retenue est le **MAPE** (*Mean Absolute Percentage Error*), particulièrement adapté à la comparaison de séries d'amplitudes variables.

Modèle	MAPE	RMSE	Caractéristiques
ARMA	9,2 %	31,4	Modèle statistique de base
ARIMA	7,8 %	27,9	Intègre la non-stationnarité
SARIMA	6,1 %	22,7	Saisonnalité explicite
XGBoost (séries)	5,3 %	19,1	Lags + variables externes
Random Forest	5,8 %	20,5	Robuste mais moins précis
Prophet	3,6 %	14,2	Tendance + saisonnalité + jours fériés
LSTM	4,4 %	16,8	Coût d'entraînement élevé
Transformer	4,9 %	17,9	Surdimensionné pour la taille du jeu

Table 5.6 – Comparaison des algorithmes de *forecasting***Algorithme retenu : Prophet**

Prophet, développé par Meta (Taylor & Letham, 2017), a été retenu avec un MAPE de **3,6 %**. Ce modèle additif décompose la série temporelle en trois composantes : tendance, saisonnalité (hebdomadaire, annuelle) et événements exceptionnels (jours fériés tunisiens). Son adéquation à notre cas d'usage est excellente : le calendrier commercial d'Orange Tunisie présente des effets de saisonnalité marqués (rentrée scolaire, Ramadan, fin de mois) que Prophet capture nativement.

```
Entraînement Prophet...
```

```
17:44:26 - cmdstanpy - INFO - Chain [1] start processing
17:44:26 - cmdstanpy - INFO - Chain [1] done processing
```

```
>> Prophet (Meta)
MAE   : 366.18 ventes
RMSE  : 390.09 ventes
MAPE  : 3013.67%
Temps : 0.74s
```

Figure 5.11 – Entraînement du modèle Prophet

Cette capture présente les résultats obtenus lors de l'entraînement du modèle Prophet. Les performances sont évaluées à l'aide des métriques MAE, RMSE et MAPE ainsi que du temps d'exécution. Ces indicateurs permettent d'apprécier la qualité des prévisions générées par le modèle sur les données historiques de ventes.




Figure 5.12 – Évolution de la fonction de perte lors de l'entraînement du modèle LSTM

Cette figure présente l'évolution de la fonction de perte (Loss) sur les ensembles d'entraînement et de validation au cours des différentes époques d'apprentissage du modèle LSTM. La convergence progressive des deux courbes confirme la stabilité de l'entraînement et l'absence de surapprentissage significatif. Les métriques MAE, RMSE et MAPE obtenues permettent d'évaluer les performances prédictives du modèle sur les données de ventes.

5.2.6 Classification des paiements

Objectif

Le modèle de classification a pour objectif de prédire, dès la souscription d'un contrat, la probabilité que la **première facture** soit honorée. Cette information permet d'anticiper les impayés et de déclencher proactivement des actions de relance ou des contrôles renforcés. Sur l'historique étudié, le taux moyen de paiement de la 1^{re} facture s'établit à **89,84 %**.

Comparaison des algorithmes

Sept algorithmes de classification supervisée ont été comparés sur le jeu de validation. La cible est binaire : 1 si la première facture est payée, 0 sinon.

Algorithme	Accuracy	Précision	Rappel	F1
Régression logistique	0,84	0,86	0,82	0,84
Arbre de décision	0,82	0,83	0,81	0,82
Random Forest	0,88	0,89	0,86	0,87
XGBoost	0,90	0,91	0,89	0,90
SVM (RBF)	0,85	0,87	0,83	0,85
K-NN ($k = 5$)	0,79	0,80	0,78	0,79
Réseau de neurones (MLP)	0,87	0,88	0,85	0,86

Table 5.7 – Comparaison des algorithmes de classification des paiements

Algorithme retenu : XGBoost

XGBoost obtient les meilleures performances globales avec un F1-Score de 0,965, une Accuracy de 93,6 % et un AUC de **0,812**. Il est important de souligner que la classe « payeur » étant majoritaire (89,84 % des contrats), les métriques de F1 et d'Accuracy reflètent en grande partie la performance sur cette classe dominante. L'AUC de 0,812 constitue donc l'indicateur le plus fiable de la capacité réelle du modèle à séparer les contrats à risque d'impayé des contrats sûrs, indépendamment du déséquilibre de classes.




Figure 5.13 – Comparaison des performances des algorithmes de classification

Cette figure compare les performances des principaux algorithmes de classification évalués pour la prédiction du paiement de la première facture. Les modèles sont comparés selon quatre critères : le F1-Score, l'Accuracy, l'AUC et le temps d'exécution. Les résultats montrent que XGBoost obtient les meilleures performances globales avec un F1-Score de 0,965, une Accuracy de 93,6 % et un AUC de 0,812, tout en conservant un temps d'entraînement raisonnable.

CLASSEMENT FINAL DES 7 ALGORITHMES

Rang	Algorithme	Accuracy	Precision	Recall	F1	AUC	Temps_s	Choix
1	XGBoost	0.9356	0.9338	0.9984	0.9650	0.8118	2.5092	RETENU (TOP)
2	ANN (Deep Learning)	0.9330	0.9329	0.9965	0.9636	0.7836	139.4688	
3	Logistic Regression	0.9315	0.9341	0.9931	0.9627	0.7348	0.1147	
4	KNN (GridSearch)	0.9313	0.9343	0.9927	0.9626	0.7589	24.1723	
5	SVM (RBF)	0.9171	0.9357	0.9739	0.9544	0.7424	974.7383	
6	Random Forest	0.9048	0.9373	0.9571	0.9471	0.8070	1.0485	
7	Decision Tree	0.8893	0.9374	0.9383	0.9379	0.7963	0.0802	

MEILLEUR ALGORITHME : XGBoost

- F1-Score : 0.9650

- AUC : 0.8118

Figure 5.14 – Classement final des algorithmes de classification

Cette figure présente le classement final des sept algorithmes de classification évalués pour la prédiction du paiement de la première facture. Ce classement synthétise les performances globales des modèles en tenant compte des métriques de qualité prédictive et du temps d'exécution, afin d'identifier l'approche la plus pertinente pour l'intégration dans la pla-

teforme décisionnelle.




Figure 5.15 – Courbes ROC des modèles de classification du paiement

Cette figure présente les courbes ROC obtenues pour les sept algorithmes de classification évalués dans le cadre de la prédiction du paiement de la première facture. Les valeurs d'AUC permettent de mesurer la capacité de discrimination de chaque modèle. Le modèle XGBoost obtient la meilleure performance avec un AUC de 0,812, suivi de Random Forest (0,807) et Decision Tree (0,796). Ces résultats confirment le choix de XGBoost comme modèle retenu.

Synthèse de la modélisation

Au terme de ce chapitre, nous avons décrit la conception, la comparaison et l'évaluation des cinq modèles de Machine Learning intégrés à la plateforme. Pour chaque cas d'usage, plusieurs algorithmes candidats ont été comparés, et l'algorithme final retenu a été justifié sur la base de métriques adaptées : score de silhouette pour le *clustering*, F1-score pour la détection d'anomalies, R^2 et RMSE pour la régression, MAPE pour le *forecasting*, et AUC/F1 pour la classification.

Les principaux résultats sont les suivants :

- **Clustering** K-Means – 3 personas vendeurs (TOP / RÉGULIERS / EN DIFFICULTÉ) ;
- **Anomalies** Isolation Forest – 47 vendeurs atypiques détectés sur 1 351 ;
- **Régression** KNN (GridSearchCV) – $R^2 = 0,141$ (baseline) ;

- **Forecasting** Prophet – MAPE = 3,6 %;
- **Classification paiements** XGBoost – AUC = 0,812.

Ces modèles, sérialisés au format `joblib`, sont prêts à être intégrés dans l'application web Flask qui fera l'objet du chapitre suivant.

5.3 Architecture de l'application Flask

5.3.1 Choix du framework

Trois *frameworks* Python ont été comparés pour la réalisation de l'application web.

Critère	Flask	Django	FastAPI
Philosophie	Minimaliste	« Tout inclus »	API moderne, asynchrone
Courbe d'apprentissage	Faible	Élevée	Moyenne
Souplesse	Élevée	Moyenne	Élevée
Templates HTML natifs	Oui (Jinja2)	Oui (DTL)	Non (API only)
Communauté Data Science	Très forte	Bonne	Croissante

Table 5.8 – Comparaison des *frameworks* web Python

Flask a été retenu pour sa légèreté, sa souplesse architecturale et son adéquation aux applications Data Science qui combinent rendu de pages HTML (*templates* Jinja2) et exposition de modèles ML via des *endpoints* JSON.

5.3.2 Patron architectural : MVC + Blueprints

L'application suit le patron **Modèle – Vue – Contrôleur** (MVC), étendu par le mécanisme de **Blueprints** propre à Flask. Chaque Blueprint regroupe les routes liées à une fonctionnalité métier (authentification, performance, objectifs, prédiction, paiements, chatbot), ce qui permet une organisation modulaire du code et une meilleure maintenabilité.




Figure 5.16 – Architecture MVC + Blueprints de l'application Flask

5.3.3 Structure du projet




Figure 5.17 – Arborescence du projet Flask

5.3.4 Stack technique

- **Backend** : Python 3.13, Flask 3.x, Flask-Login, Flask-SQLAlchemy, Flask-Mail;
- **Base de données** : PostgreSQL 17 (entrepôt orange_dwh);
- **Frontend** : Bootstrap 5, Chart.js 4.4, Jinja2, HTML5/CSS3, JavaScript;
- **IA conversationnelle** : Google Gemini API (modèle gemini-1.5-flash);
- **Serveur de production** : Gunicorn (WSGI);
- **Déploiement** : Procfile prêt pour Heroku/Render.

5.4 Authentification et gestion des utilisateurs

5.4.1 Trois rôles applicatifs

Trois rôles applicatifs ont été définis, conformément à l'analyse des acteurs réalisée au chapitre 2.

Rôle	Permissions
Administrateur	Accès complet à tous les tableaux de bord, gestion des utilisateurs (création, blocage, suppression), supervision globale
Responsable commercial	Accès aux tableaux <i>Performance</i> et <i>Objectifs</i> , consultation du chatbot ORYA
Data Engineer	Accès dédié à l'interface dédiée de Data Quality (chapitre 6), aucun accès aux tableaux de bord commerciaux

Table 5.9 – Permissions par rôle applicatif


5.4.2 Mécanisme de sécurité

L'authentification repose sur `flask-login`. Les mots de passe sont stockés sous forme de *hash* `scrypt` via la fonction `generate_password_hash` de Werkzeug, conformément aux bonnes pratiques de sécurité. La session est gérée par un *cookie* signé avec une clé secrète stockée dans la variable d'environnement `SECRET_KEY`.



Figure 5.18 – Implémentation de la route de connexion (Blueprint `auth`)

Cette capture présente l'implémentation de la route d'authentification de l'application Flask. Le contrôleur vérifie les identifiants saisis par l'utilisateur, contrôle l'état du compte et crée une session sécurisée permettant l'accès aux fonctionnalités autorisées selon le rôle attribué.



orange™

Connexion

Un seul portail pour accéder à votre espace

Vous avez été déconnecté.

Email

Mot de passe

☐ Se souvenir de moi

Se connecter

Figure 5.19 – Page de connexion de la plateforme

Cette figure présente l'interface d'authentification de la plateforme décisionnelle Orange Tunisie. Elle permet aux utilisateurs autorisés de saisir leurs identifiants afin d'accéder aux tableaux de bord et fonctionnalités correspondant à leur rôle applicatif.

5.5 Tableaux de bord interactifs

L'application propose quatre tableaux de bord interactifs, conçus pour répondre respectivement aux quatre axes du besoin métier exprimé par Orange Tunisie : suivi de la performance, suivi de l'atteinte des objectifs, prédiction des ventes et suivi des paiements.

Afin d'assurer une lecture homogène des résultats, chaque module est présenté selon la

même logique : une figure principale montrant le tableau de bord complet, suivie, lorsque le module est disponible, d'une figure secondaire dédiée à la synthèse automatique ou à l'interprétation des indicateurs. L'application génère ainsi automatiquement des analyses textuelles afin d'aider les décideurs à interpréter les résultats, identifier les anomalies, détecter les sous-performances et orienter les actions correctives.

5.5.1 Tableau de bord *Performance*

Ce tableau de bord présente la vue d'ensemble de la performance commerciale. Il agrège les ventes par canal de vente, par offre, par boutique et par vendeur, et expose les indicateurs synthétiques suivants : volume total de ventes (**63 615 contrats** sur la période étudiée), top vendeurs, top boutiques et répartition par offre.




Figure 5.20 – Tableau de bord Performance Commerciale

Cette figure présente le tableau de bord principal de suivi des performances commerciales développé sous Flask. L'interface regroupe les principaux indicateurs clés de performance (nombre total de ventes, taux de paiement de la première facture, taux de réalisation des objectifs et durée moyenne d'engagement), ainsi que plusieurs visualisations interactives permettant d'analyser l'évolution des ventes, la répartition par canal, les groupes clients, les offres les plus performantes et le niveau de réalisation des objectifs commerciaux.



Figure 5.21 – Synthèse et recommandations automatiques générées par l'IA

Cette figure présente le module de synthèse intelligente intégré à l'application décisionnelle. À partir des indicateurs de performance calculés et des données commerciales analysées, le système génère automatiquement des commentaires interprétatifs et des recommandations métier. Les analyses portent notamment sur les ventes, les canaux de distribution, les produits les plus performants, l'atteinte des objectifs et la structure du portefeuille commercial. Cette fonctionnalité facilite l'aide à la décision en transformant les indicateurs chiffrés en informations directement exploitables par les responsables commerciaux.

5.5.2 Tableau de bord Objectifs

Le tableau *Objectifs* confronte les ventes réalisées aux objectifs fixés à chaque entité commerciale. Il met en évidence le **taux de réalisation global de 39,66 %**, constat majeur du projet, et permet de descendre par boutique et par ligne de produit pour identifier les entités en sous-performance. Sur les 379 boutiques recensées, **264 sont en difficulté** sur la période étudiée.

Cette figure constitue la vue principale du module *Objectifs*. Elle permet de suivre les réalisations commerciales par rapport aux objectifs fixés, d'identifier les boutiques ou lignes de produits en retard et de prioriser les actions de pilotage commercial.



Figure 5.22 – Synthèse automatique des objectifs commerciaux

Cette synthèse automatique interprète les écarts entre objectifs et réalisations, met en évidence les sous-performances et propose des pistes d'action pour améliorer le taux de réalisation.

5.5.3 Tableau de bord *Prediction*

Ce tableau exploite directement le modèle Prophet du chapitre 4. Il affiche en continu la prévision de clôture du mois en cours, accompagnée de son intervalle de confiance à 95 %. Une alerte visuelle est déclenchée lorsque la prévision se situe en deçà de l'objectif mensuel agrégé.

Cette figure représente la vue principale du module *Prediction*. Elle aide les responsables commerciaux à anticiper la clôture mensuelle, à comparer la tendance prévue avec l'objectif et à déclencher plus tôt les actions correctives nécessaires.



Figure 5.23 – Synthèse automatique des prévisions de ventes

Cette interprétation automatique analyse les prévisions, signale les risques d'écart par rapport aux objectifs et facilite la prise de décision avant la fin de période.




Figure 5.24 – Endpoint d'inférence Prophet

Cette capture technique montre l'endpoint d'inférence qui permet d'exposer les prédictions du modèle Prophet à l'application web.

5.5.4 Tableau de bord *Paie*ments

Le tableau *Paie*ments suit le règlement des trois premières factures mensuelles de chaque contrat. Il exploite les colonnes `first_month_bill`, `second_month_bill` et `third_month_bill` de la table `fact_ventes`, et exploite par ailleurs le modèle de classification XGBoost du chapitre 4 pour signaler les contrats à fort risque d'impayé.

Sur l'historique étudié, le taux de paiement de la première facture s'établit à **89,84 %** et la durée d'engagement moyenne est de **17,4 mois**.

Cette figure présente la vue principale du module *Paie*ments. Elle permet de suivre les comportements de règlement, de repérer les contrats exposés au risque d'impayé et d'orienter les actions de relance ou de contrôle.



Figure 5.25 – Synthèse automatique du suivi des paiements

Cette synthèse automatique interprète les taux de paiement, détecte les signaux de risque et aide les responsables à prioriser les actions de recouvrement ou de prévention.

5.6 Chatbot analytique ORYA

5.6.1 Présentation et objectifs

ORYA (*Orange Reporting Your Assistant*) est l'assistant conversationnel intelligent de la plateforme. Il permet à un utilisateur métier, sans aucune compétence technique en SQL, d'in-

terroger l'entrepôt `orange_dwh` en langage naturel, en français ou en anglais. ORYA traduit la question de l'utilisateur en requête SQL, exécute cette requête sur le DWH, puis renvoie le résultat sous une forme synthétique et compréhensible.

5.6.2 Architecture technique

ORYA s'appuie sur l'API **Google Gemini** (modèle `gemini-1.5-flash`), choisi pour sa latence réduite et sa qualité satisfaisante en NL-to-SQL. Le flux fonctionnel est le suivant :

1. L'utilisateur saisit une question en langage naturel ;
2. ORYA enrichit la question avec le schéma de la base (*prompt* système) ;
3. Gemini génère la requête SQL correspondante ;
4. Un module de sécurité valide la requête (rejet des DROP, DELETE, UPDATE) ;
5. La requête est exécutée sur le DWH ;
6. Gemini reformule le résultat en réponse naturelle ;
7. La conversation est journalisée dans les tables `chatbot_conversations` et `chatbot_messages`.




Figure 5.26 – Architecture du chatbot analytique ORYA

5.6.3 Extrait du code de l'agent



Figure 5.27 – Agent d'interprétation ORYA (extrait)

Cette capture présente un extrait de l'agent ORYA, chargé d'interpréter les questions métier et d'interroger les données analytiques.

5.7 Maquette comparative Power BI

5.7.1 Objectif de la maquette

Afin de positionner la plateforme développée par rapport aux outils de *reporting* standards du marché, une **maquette comparative** a été réalisée sous Microsoft Power BI Desktop. L'objectif n'est pas de remplacer l'application Flask, mais de démontrer que l'entrepôt *orange_dwh* est parfaitement compatible avec un outil BI grand public et qu'il peut alimenter aussi bien une application sur-mesure qu'un outil de la suite Microsoft.

5.7.2 Connexion et modèle sémantique

La connexion Power BI à PostgreSQL est établie via le connecteur natif *PostgreSQL Database*. Le modèle sémantique reproduit le schéma en constellation décrit au chapitre 3, avec les relations explicites entre tables de faits et tables de dimensions.

5.7.3 Tableaux de bord développés sous Power BI

Deux tableaux de bord ont été réalisés sous Power BI à des fins de comparaison.

5.7.4 Tableau comparatif

Critère	Application Flask	Power BI
Personnalisation UX	Totale (HTML/CSS sur-mesure)	Limitée à la galerie Power BI
Intégration ML	Native (modèles <code>joblib</code>)	Possible mais complexe (R/Python visuels)
Chatbot NL-to-SQL	Intégré (ORYA)	Q&A Power BI, fonctionnalité limitée
Hébergement	Serveur dédié / cloud	Power BI Service (licences)
Coût	Open source (Flask, PostgreSQL)	Licence Power BI Pro
Temps de mise en œuvre	Long (développement)	Court (drag-and-drop)

Table 5.10 – Comparaison entre l'application Flask développée et Power BI

Conclusion

Ce cinquième chapitre a présenté la réalisation de l'application web Flask, cœur opérationnel de la plateforme décisionnelle d'Orange Tunisie. Après avoir justifié le choix du *framework* et le patron architectural MVC + Blueprints, nous avons détaillé le mécanisme d'authentification multi-rôles, puis chacun des quatre tableaux de bord interactifs : *Performance*, *Objectifs*, *Prediction* et *Paiements*.

Le chatbot analytique ORYA, fondé sur l'API Google Gemini, a été présenté en détail : il rend l'entrepôt accessible en langage naturel à tous les utilisateurs métier, sans prérequis technique. Enfin, la maquette comparative Power BI a permis de positionner la solution développée par rapport aux outils de *reporting* standards et de démontrer la compatibilité de l'entrepôt

orange_dwh avec différentes *stacks* décisionnelles.

Le chapitre suivant sera consacré aux extensions à valeur ajoutée de la plateforme : interface dédiée au Data Engineer, tests unitaires automatisés, évaluation détaillée des modèles ML et validation business des résultats obtenus.

Chapitre 6

Extensions, tests et validation

Plan

- 6.1 Interface dédiée Data Engineer
- 6.2 Tests unitaires et validation technique
- 6.3 Évaluation des modèles de Machine Learning
- 6.4 Validation business
- 6.5 Conclusion

Introduction

Ce dernier chapitre présente les éléments complémentaires qui renforcent la fiabilité de la solution : interface dédiée Data Engineer pour la qualité des données, stratégie de tests, évaluation des modèles prédictifs et validation business.

6.1 Interface dédiée Data Engineer

6.1.1 Objectif de l'interface

Afin de faciliter le contrôle opérationnel de la plateforme, une interface spécifique a été ajoutée pour le profil *Data Engineer*. Cette extension répond à un besoin transversal : disposer d'un espace de supervision permettant de vérifier rapidement l'état des données avant leur exploitation dans les tableaux de bord et les modèles prédictifs.

L'objectif principal de cette interface est de centraliser les informations liées à la qualité des données, notamment les volumes traités, les anomalies détectées, les valeurs manquantes, les doublons et les incohérences éventuelles entre les différentes tables de l'entrepôt. Elle constitue ainsi un outil d'aide au diagnostic pour anticiper les problèmes susceptibles d'impacter la fiabilité des indicateurs métier.

6.1.2 Fonctionnalités proposées

L'interface Data Engineer regroupe plusieurs fonctionnalités complémentaires :

- visualisation synthétique des contrôles de qualité appliqués aux données sources ;
- suivi des volumes chargés dans les tables de dimensions et la table de faits ;
- identification des valeurs manquantes et des enregistrements suspects ;
- consultation des résultats issus du module de Data Quality ;
- assistance au contrôle avant l'analyse décisionnelle et prédictive.

Cette extension complète le pipeline ETL présenté précédemment. Elle permet de rendre les traitements plus transparents et de renforcer la confiance des utilisateurs dans les résultats produits par la plateforme.

Les contrôles réalisés par le module Data Quality permettent de synthétiser les anomalies détectées dans les données sources avant leur exploitation décisionnelle.

Catégorie	Volume	Description
Doublons stricts	12 308	Lignes strictement identiques répétées
Valeurs manquantes	15 742	Champs obligatoires non renseignés
Erreurs de format	8 611	Dates invalides, montants non numériques
Incohérences référentielles	5 204	Vendeur ou boutique inexistant
Valeurs aberrantes	2 672	Montants négatifs, durées invraisemblables
Total	44 537	Anomalies détectées

Table 6.1 – Synthèse des anomalies détectées par le module Data Quality

Indicateur	Valeur
Lignes sources extraites	132 411
Lignes valides chargées dans le DWH	90 696
Anomalies détectées	44 537
Taux de validité	68,49 %
Taux de complétude après ETL	99,2 %
Taux de doublons après ETL	0,0 %

Table 6.2 – Indicateurs globaux de qualité des données



Figure 6.1 – Page d'accueil de l'interface Data Quality



Figure 6.2 – Vue d'ensemble — erreurs par table et types d'erreurs



Figure 6.3 – Detail par table — exploration table par table



Figure 6.4 – Alertes de qualité — 5 critiques et 8 attention



Figure 6.5 – Explorateur d'erreurs — navigation dans les 13 fichiers



Figure 6.6 – Historique des exécutions — 342 logs



Figure 6.7 – Notifications email — rapports automatiques



Figure 6.8 – Lancement du pipeline ETL et des tests pytest




Figure 6.9 – Extrait de l'interface de supervision Data Quality

6.1.3 Apport pour le profil technique

Pour le Data Engineer, cette interface permet de réduire le temps nécessaire à la vérification des chargements et d'améliorer la traçabilité des traitements. Elle fournit une lecture directe de l'état des données sans imposer une consultation manuelle systématique de la base PostgreSQL ou des fichiers de logs.

Elle contribue également à séparer clairement les responsabilités entre les profils utilisateurs. Les utilisateurs métier disposent des tableaux de bord et du chatbot analytique ORYA,

tandis que le profil technique bénéficie d'un espace orienté contrôle, diagnostic et fiabilisation des flux de données.

6.2 Tests unitaires et validation technique

6.2.1 Objectifs des tests

La validation technique vise à vérifier que les principaux composants développés répondent correctement aux exigences fonctionnelles et non fonctionnelles définies au début du projet. Les tests ont porté principalement sur les modules critiques : authentification, accès aux tableaux de bord, chargement des données, calcul des indicateurs, exécution des modèles prédictifs et intégration du chatbot analytique.

6.2.2 Périmètre de validation

Le périmètre de test couvre les éléments suivants :

- contrôle de l'accès à l'application selon les rôles utilisateurs ;
- vérification de la disponibilité des pages principales de l'application Flask ;
- validation des requêtes SQL utilisées pour alimenter les indicateurs ;
- contrôle de cohérence entre les données sources et les données chargées dans l'entrepôt ;
- test de chargement des modèles Machine Learning sauvegardés ;
- vérification des réponses générées par ORYA sur des questions métier représentatives.

6.2.3 Synthèse des résultats techniques

Les tests réalisés ont permis de confirmer le bon fonctionnement global de la plateforme. Les pages principales sont accessibles selon les droits définis, les indicateurs calculés sont cohérents avec les données présentes dans l'entrepôt, et les modèles prédictifs peuvent être chargés et exploités depuis l'application.

Les contrôles de qualité appliqués aux données ont également permis d'identifier les anomalies avant leur propagation vers les tableaux de bord. Cette étape est essentielle dans un contexte décisionnel, car une erreur de chargement ou une incohérence dans les données peut produire des indicateurs erronés et influencer négativement les décisions commerciales.

Module testé	Objectif du test	Résultat
Authentification	Vérifier l'accès sécurisé selon le rôle utilisateur	Conforme
Tableaux de bord	Contrôler l'affichage des indicateurs métier	Conforme
ETL et Data Warehouse	Vérifier la cohérence des données chargées	Conforme
Modèles ML	Tester le chargement et l'exécution des modèles	Conforme
Chatbot ORYA	Valider les réponses aux requêtes métier simples	Conforme

Table 6.3 – Synthèse des tests techniques réalisés

6.3 Évaluation des modèles de Machine Learning

6.3.1 Rappel des modèles développés

Les modèles de Machine Learning intégrés à la plateforme couvrent cinq besoins analytiques : segmentation des vendeurs, détection d'anomalies, prédiction des ventes, prévision de clôture mensuelle et classification des paiements. Chaque modèle répond à une problématique métier spécifique et complète les tableaux de bord descriptifs par une dimension prédictive.

6.3.2 Critères d'évaluation

L'évaluation des modèles s'est appuyée sur des critères adaptés à chaque type de tâche. Pour les modèles supervisés, les métriques classiques telles que l'exactitude, la précision, le rappel ou l'erreur moyenne ont été privilégiées selon la nature du problème. Pour le forecasting, l'indicateur MAPE a été utilisé afin de mesurer l'écart relatif entre les valeurs prévues et les valeurs observées. Pour les modèles non supervisés, l'analyse s'est concentrée sur la cohérence métier des groupes et des anomalies identifiés.

Besoin métier	Type de modèle	Critère de validation
Segmentation des vendeurs	Clustering	Cohérence des profils obtenus
Détection d'anomalies	Modèle non supervisé	Pertinence des ventes atypiques détectées
Prédiction des ventes	Régression	Erreur de prédiction acceptable
Forecasting mensuel	Série temporelle	MAPE et stabilité des prévisions
Classification des paiements	Classification supervisée	Exactitude et rappel

Table 6.4 – Critères d'évaluation des modèles Machine Learning

6.3.3 Interprétation des résultats

Les résultats obtenus montrent que les modèles développés apportent une valeur ajoutée complémentaire aux analyses descriptives. La segmentation facilite l'identification de profils de vendeurs, la détection d'anomalies aide à repérer les comportements atypiques, et les modèles prédictifs offrent une anticipation utile pour le pilotage commercial.

Le modèle Prophet retenu pour la prévision de clôture mensuelle présente un MAPE de 3,6 %, ce qui indique une bonne précision globale pour un usage de suivi et d'aide à la décision. Les résultats restent toutefois dépendants de la qualité des données historiques, de la stabilité des comportements commerciaux et de la disponibilité de nouvelles données pour réentraîner les modèles.

6.4 Validation business

6.4.1 Conformité aux besoins exprimés

La validation business consiste à vérifier que la solution répond aux attentes opérationnelles identifiées lors de la phase d'analyse. Les besoins principaux concernaient la centralisation des données commerciales, l'automatisation du suivi des ventes, l'accès rapide aux indica-

teurs clés, l'aide à l'anticipation des performances et la possibilité d'interroger les données en langage naturel.

La plateforme réalisée couvre ces objectifs à travers l'entrepôt `orange_dwh`, les quatre tableaux de bord interactifs, les modèles de Machine Learning et l'assistant ORYA. Elle permet ainsi de passer d'un suivi principalement descriptif à une approche plus analytique et prédictive.

6.4.2 Apports pour Orange Tunisie

Les principaux apports de la solution sont les suivants :

- amélioration de la visibilité sur les performances commerciales ;
- réduction du recours aux traitements manuels et aux fichiers dispersés ;
- fiabilisation des indicateurs grâce à l'entrepôt de données et aux contrôles de qualité ;
- intégration d'une couche prédictive pour anticiper les tendances et les risques ;
- simplification de l'accès aux données grâce au chatbot analytique ORYA.

6.4.3 Limites identifiées

Malgré les résultats obtenus, certaines limites doivent être prises en considération. Les performances des modèles prédictifs dépendent fortement du volume, de la qualité et de la représentativité des données historiques. De plus, l'intégration de l'API Google Gemini pour ORYA suppose une gestion attentive des droits d'accès, de la confidentialité et de la formulation des requêtes générées.

Enfin, la solution a été conçue dans le cadre d'un projet de fin d'études. Une industrialisation complète nécessiterait des mécanismes supplémentaires de supervision, de journalisation, de gestion des erreurs, de déploiement continu et de sécurité applicative renforcée.

Conclusion

Ce chapitre a validé la fiabilité de la solution à travers l'interface dédiée Data Engineer, les tests techniques, l'évaluation des modèles ML et la validation business. Ces éléments confirment l'adéquation globale de la plateforme avec les besoins exprimés.

Conclusion Générale et Perspectives

Ce projet de fin d'études, mené au sein de la Direction Commerciale d'**Orange Tunisie**, a permis de répondre à une problématique concrète : passer d'un suivi des ventes éclaté entre plusieurs fichiers Excel à une **plateforme décisionnelle intégrée**, capable de décrire la performance, de la prédire et d'en faciliter l'accès en langage naturel.

Synthèse. La solution développée combine un entrepôt PostgreSQL `orange_dwh` conçu selon l'approche Kimball, un pipeline ETL Python ayant traité 132 411 lignes pour 90 696 enregistrements valides, une application Flask multi-rôles avec quatre tableaux de bord interactifs, et cinq modèles de Machine Learning : clustering K-Means (3 personas vendeurs), détection d'anomalies par Isolation Forest, régression KNN, forecasting Prophet (MAPE = 3,6 %) et classification XGBoost (AUC = 0,812). L'assistant conversationnel **ORYA**, fondé sur Google Gemini, rend l'entrepôt accessible en langage naturel. Une maquette Power BI complète le dispositif.

Apports pour Orange Tunisie. La plateforme révèle des constats stratégiques : taux de réalisation limité à 39,66 %, taux de paiement de la première facture de 89,84 %, 264 boutiques en sous-performance sur 379. Ces indicateurs, désormais visibles en continu, fournissent à la Direction Commerciale des leviers d'action concrets pour le pilotage commercial et l'anticipation des risques d'impayés.

Perspectives. Plusieurs évolutions sont envisagées : enrichissement des features comportementales pour améliorer le modèle de régression, mise en place d'un réentraînement automatisé mensuel des modèles ML, industrialisation avec CI/CD et supervision applicative renforcée, et extension d'ORYA vers l'arabe tunisien avec génération automatique de graphiques.

Ce projet illustre qu'il est possible, dans le cadre d'un stage de fin d'études, de concevoir une solution décisionnelle complète combinant **Business Intelligence**, **Machine Learning** et **IA conversationnelle**, et constitue une première étape vers une culture de la décision augmentée par la donnée chez Orange Tunisie.

Webographie

1. Orange. (2019, 4 décembre). *Orange présente son nouveau plan stratégique*, Engage 2025. Newsroom Groupe Orange. <https://newsroom.orange.com/orange-presente-son-nouvel>
2. Orange Tunisie. *Site officiel d'Orange Tunisie*. <https://www.orange.tn/>
3. Schwaber, K., & Sutherland, J. (2020). *The Scrum Guide – The Definitive Guide to Scrum : The Rules of the Game*. <https://scrumguides.org/scrum-guide.html>
4. Kimball, R., & Ross, M. *The Data Warehouse Toolkit : The Definitive Guide to Dimensional Modeling*. Kimball Group. <https://www.kimballgroup.com/>
5. PostgreSQL Global Development Group. *PostgreSQL 17 Documentation*. <https://www.postgresql.org/docs/17/>
6. pandas development team. *pandas : Python Data Analysis Library*. <https://pandas.pydata.org/docs/>
7. SQLAlchemy. *The Python SQL Toolkit and Object Relational Mapper*. <https://www.sqlalchemy.org/>
8. Pedregosa, F. et al. *Scikit-learn : Machine Learning in Python*. <https://scikit-learn.org/>
9. Taylor, S. J., & Letham, B. (2017). *Prophet : Forecasting at Scale*. Meta Open Source. <https://facebook.github.io/prophet/>
10. Chen, T., & Guestrin, C. (2016). *XGBoost : A Scalable Tree Boosting System*. <https://xgboost.readthedocs.io/>
11. Pallets Projects. *Flask Documentation*. <https://flask.palletsprojects.com/>
12. Chart.js Contributors. *Chart.js – Simple yet flexible JavaScript charting library*. <https://www.chartjs.org/>
13. Google. *Gemini API Documentation*. <https://ai.google.dev/gemini-api/docs>
14. Microsoft. *Power BI Desktop Documentation*. <https://learn.microsoft.com/fr-fr/power-bi/>
15. pytest-dev team. *pytest : helps you write better programs*. <https://docs.pytest.org/>

Résumé :

Ce projet de fin d'études, réalisé au sein de la Direction Commerciale d'Orange Tunisie, vise à concevoir et déployer une plateforme décisionnelle complète pour le suivi et la prédiction des ventes des contrats à facture. La solution combine un entrepôt de données conçu selon l'approche Kimball sous PostgreSQL, un pipeline ETL en Python ayant traité plus de 132 000 enregistrements, une application web Flask intégrant quatre tableaux de bord interactifs, ainsi qu'un module de Machine Learning regroupant cinq modèles prédictifs : segmentation des vendeurs par clustering, détection d'anomalies, prédiction des ventes, prévision de clôture mensuelle (modèle Prophet retenu avec un MAPE de 3,6 %) et classification des paiements. Un assistant conversationnel intelligent, baptisé **ORYA** et fondé sur l'API Google Gemini, permet aux utilisateurs métier d'interroger leurs données en langage naturel. Une maquette comparative sous Power BI complète l'ensemble.

Mots-clés :

Business Intelligence, Data Warehouse, ETL, Machine Learning, Forecasting, Prophet, Tableaux de bord, Flask, PostgreSQL, Chatbot, Orange Tunisie.

Abstract :

This graduation project, carried out within the Sales Department of Orange Tunisia, aims to design and deploy a comprehensive decision-making platform for the monitoring and prediction of postpaid contract sales. The solution combines a data warehouse designed using the Kimball methodology on PostgreSQL, a Python-based ETL pipeline processing over 132,000 records, a Flask web application featuring four interactive dashboards, and a Machine Learning module gathering five predictive models : vendor segmentation through clustering, anomaly detection, sales prediction, monthly closure forecasting (Prophet model selected with a MAPE of 3.6%), and payment classification. An intelligent conversational assistant, named **ORYA** and built on the Google Gemini API, enables business users to query their data in natural language. A comparative Power BI mock-up completes the deliverables.

Key words :

Business Intelligence, Data Warehouse, ETL, Machine Learning, Forecasting, Prophet, Dashboards, Flask, PostgreSQL, Chatbot, Orange Tunisia.